UNIVERSIDAD DE CANTABRIA

Escuela Técnica Superior de Ingeniería Informática

Sistema Multiagente de Inversión basado en LLM sobre el S&P 500

Trabajo Fin de Grado
Grado en Ingeniería Informática

Autor:
Fernando Porres Sangador

Tutor:
Carlos Blanco Bueno

Santander, 2026

Resumen

La toma de decisiones de inversión en mercados financieros es un problema complejo en el cual se combina el análisis técnico, el fundamental y de sentimiento, con horizontes temporales inciertos y gran cantidad de información heterogénea. Los enfoques tradicionales de inversión algorítmica abordan estas dimensiones de forma aislada, lo que limita su capacidad de capturar la dinámica real del mercado.

Este trabajo propone un sistema multiagente de inversión que integra modelos de lenguaje de gran escala (LLM), modelos de aprendizaje automático y análisis de sentimiento sobre noticias financieras para generar señales de inversión (compra, mantenimiento o venta) sobre un subconjunto de 50 acciones del índice S&P 500. El sistema se diseña en torno a agentes especializados; técnico, fundamental, de riesgo, de sentimiento y de simulación estocástica; coordinados por un orquestador que adapta la decisión final al perfil de riesgo del inversor.

Se desarrollan y comparan dos arquitecturas: la primera basada íntegramente en LLM (Mistral 7B), y una segunda híbrida, la cual sustituye cuatro de los cinco agentes por Random Forest especializados entrenados sobre indicadores técnicos y de riesgo, FinBERT para el análisis de sentimiento, y simulación Monte Carlo para el cálculo estocástico reservando el LLM solamente para la orquestación final. Ambas se evalúan mediante backtesting histórico sobre el periodo 2019–2024 y se comparan con estrategias de referencia basadas en señales cuantitativas (RSI, MACD) y compra y mantenimiento.

Palabras clave: sistema multiagente, LLM, Random Forest, FinBERT, análisis de sentimiento, inversión algorítmica, S&P 500, backtesting.

Abstract

Investment decision-making in financial markets is a complex problem that combines technical, fundamental and sentiment analysis under uncertain time horizons and large volumes of heterogeneous information. Traditional algorithmic investment approaches address these dimensions in isolation, limiting their ability to capture real market dynamics.

This work proposes a multi-agent investment system that integrates large language models (LLMs), machine learning models and financial news sentiment analysis to generate investment signals (buy, hold or sell) over a subset of 50 stocks from the S&P 500 index. The system is built around specialised agents; technical, fundamental, risk, sentiment and stochastic simulation; coordinated by an orchestrator that adapts the final decision to the investor's risk profile.

Two architectures are developed and compared: the first one based entirely on LLMs (Mistral 7B), and a second hybrid one, which replaces four of the five agents with specialised models, Random Forest trained on technical and risk indicators, FinBERT for sentiment analysis, and Monte Carlo simulation for stochastic calculation, reserving the LLM solely for final orchestration. Both are evaluated through historical backtesting over the 2019–2024 period and compared against reference strategies based on quantitative signals (RSI, MACD) and buy-and-hold.

Keywords: multi-agent system, LLM, Random Forest, FinBERT, sentiment analysis, algorithmic investment, S&P 500, backtesting.

Índice general

Resumen **1**

Abstract **2**

Índice de figuras **5**

Índice de tablas **6**

1. Introducción **7**
1.1. Motivación . . . 7
1.2. Contexto y objetivos . . . 7
1.3. Estructura del trabajo . . . 8

2. Estado del arte **9**
2.1. Sistemas de inversión algorítmica . . . 9
2.2. Modelos de lenguaje en finanzas . . . 9
2.3. Sistemas multiagente . . . 10
2.4. Análisis de sentimiento financiero . . . 11

3. Fundamentos teóricos **12**
3.1. Arquitectura Transformer y LLMs . . . 12
3.2. Random Forest y métodos ensemble . . . 13
3.3. Indicadores técnicos financieros . . . 13
3.3.1. Índice de Fuerza Relativa (RSI) . . . 13
3.3.2. MACD . . . 14
3.3.3. Bandas de Bollinger . . . 15
3.4. Métricas de evaluación de carteras . . . 16
3.4.1. Retorno total y CAGR . . . 16
3.4.2. Ratio de Sharpe y Sortino . . . 16
3.4.3. Alpha, Beta y drawdown máximo . . . 17
3.4.4. Information Ratio . . . 18

4. Datos y preprocesamiento **19**
4.1. Selección de activos . . . 19
4.2. Datos de precio histórico . . . 19
4.3. Dataset de noticias financieras: FNSPID . . . 19
4.4. Análisis exploratorio . . . 20

5. Diseño del sistema **24**
5.1. Arquitectura general . . . 24
5.2. Sistema LLM puro . . . 24
5.2.1. Agentes especializados . . . 25
5.2.2. Salida estructurada con Pydantic . . . 25
5.2.3. Backtesting histórico: arquitectura simplificada . . . 26
5.3. Sistema híbrido . . . 26
5.3.1. Random Forest especializados . . . 27
5.3.2. Agente de sentimiento FinBERT . . . 27
5.3.3. Simulación Monte Carlo . . . 27
5.3.4. Orquestador Mistral . . . 28
5.4. Perfiles de riesgo . . . 28
5.5. Tecnologías utilizadas . . . 29

6. Implementación **30**
6.1. Implementación del sistema LLM puro . . . 30
6.2. Implementación del sistema híbrido . . . 31
6.3. Entrenamiento de los Random Forest especializados . . . 32
6.4. Integración de FinBERT con FNSPID . . . 32
6.5. Sistema de backtesting . . . 33
6.5.1. Función `backtesting()` . . . 33
6.5.2. Generación de señales mensuales . . . 33
6.5.3. Cálculo de métricas . . . 34

7. Evaluación y resultados **35**
7.1. Metodología del backtesting . . . 35
7.2. Señales cuantitativas . . . 35
7.3. Random Forest monolítico . . . 37
7.4. Sistema LLM puro . . . 38
7.5. Sistema híbrido . . . 39
7.6. Comparativa final . . . 41

8. Conclusiones y trabajo futuro **43**
8.1. Conclusiones . . . 43
8.2. Trabajo futuro . . . 44

Bibliografía **46**

A. Estructura del proyecto **48**

B. Tickers seleccionados del S&P 500 **50**

Índice de figuras

3.1. RSI de 14 periodos aplicado sobre AAPL (2019–2024). Las zonas sombreadas en rojo indican periodos de sobrecompra (RSI > 70). 14
3.2. MACD aplicado sobre AAPL (2019–2024). En azul la línea MACD, en rojo la línea de señal y en verde el histograma. 15
3.3. Bandas de Bollinger (20 días, 2 desviaciones) sobre AAPL (2019–2024). El panel inferior muestra el $BB\,\%$. 16
3.4. Drawdown histórico de AAPL (2019–2024). 18

4.1. Evolución normalizada de precios por sector (Base 100 = enero 2019). . . . 20
4.2. Distribución de retornos diarios por acción. 21
4.3. Matriz de correlaciones de retornos diarios (50 acciones). 22
4.4. Mapa riesgo vs rentabilidad anualizado (2019–2024). 23

5.1. Arquitectura del sistema LLM puro: cinco agentes coordinados por un orquestador. 24
5.2. Arquitectura del sistema híbrido: tres Random Forest, FinBERT y Monte Carlo coordinados por Mistral 7B. 26

7.1. Evolución del valor de cartera y drawdown para el sistema cuantitativo frente a Buy&Hold SPY (2019–2024). 36
7.2. Importancia de variables y matriz de confusión del Random Forest monolítico. 37
7.3. Evolución del valor de cartera y drawdown para el RF monolítico y el sistema cuantitativo frente a Buy&Hold SPY (2019–2024). 38
7.4. Evolución del valor de cartera del sistema LLM puro frente a Buy&Hold SPY (2019–2024). Panel inferior. 39
7.5. Evolución del valor de cartera del sistema híbrido frente a Buy&Hold SPY (2019–2024). 40
7.6. Comparativa de la evolución de cartera para todas las estrategias evaluadas (2019–2024). 42

Índice de tablas

5.1. Parámetros de los perfiles de riesgo 28
5.2. Tecnologías utilizadas en el sistema 29

7.1. Métricas del sistema cuantitativo (2019–2024) 36
7.2. Métricas del Random Forest monolítico (2019–2024) 37
7.3. Métricas del sistema LLM puro (2019–2024) 38
7.4. Métricas del sistema híbrido (2019–2024) 40
7.5. Comparativa final de todas las estrategias (2019–2024) 41

Capítulo 1

Introducción

1.1. Motivación

En los últimos años, la inteligencia artificial ha experimentado un avance sin precedentes, pasando de ser una disciplina académica a convertirse en una tecnología presente en prácticamente todos los sectores. En paralelo, los mercados financieros han evolucionado hacia entornos cada vez más complejos, donde la cantidad de información disponible supera con creces la capacidad de análisis humano.

La confluencia de ambas tendencias abre una oportunidad especialmente interesante: aplicar las capacidades de los modelos de lenguaje de gran escala y el aprendizaje automático al problema de la inversión en bolsa. La posibilidad de que un sistema informático sea capaz de procesar indicadores técnicos, noticias financieras y datos de riesgo de forma simultánea, y traducirlos en decisiones de inversión fundamentadas, representa un reto técnico de primer orden.

Este trabajo nace del interés personal por la inversión y por explorar hasta qué punto la IA puede añadir valor real en un dominio tan exigente y competitivo como los mercados financieros. La elección de un enfoque multiagente responde a la convicción de que ningún único modelo captura por sí solo toda la complejidad del problema, y de que la especialización y coordinación de múltiples agentes es una aproximación más cercana a cómo razona un inversor real.

1.2. Contexto y objetivos

La inversión algorítmica, entendida como el uso de modelos computacionales para automatizar decisiones de compra y venta en mercados financieros, lleva décadas desarrollándose. Desde los primeros sistemas basados en reglas técnicas hasta los modelos cuantitativos modernos, el objetivo ha sido siempre el mismo: explotar patrones en los datos del mercado para obtener rentabilidades superiores al índice de referencia [1]. Sin embargo, estos enfoques tradicionales presentan limitaciones importantes: operan sobre datos estructurados, ignoran información cualitativa como noticias o informes, y no adaptan su comportamiento al perfil del inversor.

En paralelo, el campo de la inteligencia artificial ha vivido una revolución con la aparición de los modelos de lenguaje de gran escala (LLM). Basados en la arquitectura Transformer [2], estos modelos son capaces de comprender y generar texto con una coherencia y profundidad antes impensables. Su aplicación al dominio financiero ha dado

lugar a modelos especializados como FinBERT [3], entrenado específicamente sobre noticias y documentos financieros para el análisis de sentimiento.

Los sistemas multiagente, por su parte, constituyen un paradigma de la inteligencia artificial distribuida en el que múltiples agentes autónomos colaboran para resolver problemas que ningún agente podría abordar de forma individual [4]. La aplicación de este paradigma a la inversión permite descomponer el problema en subproblemas especializados, análisis técnico, fundamental, de riesgo y de sentimiento, y combinar las señales resultantes mediante un orquestador que razona sobre el conjunto.

El objetivo principal de este trabajo es diseñar, implementar y evaluar un sistema multiagente de inversión que combine modelos de lenguaje de gran escala, aprendizaje automático y análisis de sentimiento financiero para generar señales de inversión automáticas sobre un subconjunto de 50 acciones del índice S&P 500, explorando el potencial de las nuevas técnicas de inteligencia artificial en el dominio financiero.

Para alcanzar este objetivo principal se plantean los siguientes objetivos secundarios:

1. Diseñar e implementar dos arquitecturas multiagente distintas: una basada íntegramente en LLM y una híbrida que combina modelos clásicos de aprendizaje automático con un LLM como orquestador, con el fin de analizar las ventajas e inconvenientes de cada enfoque.

2. Integrar análisis de sentimiento financiero sobre noticias reales mediante FinBERT y el dataset FNSPID, evaluando su contribución a la calidad de las señales generadas.

3. Diseñar un sistema de perfiles de riesgo, conservador, moderado y agresivo, que adapte automáticamente las decisiones de inversión al tipo de inversor.

4. Validar ambas arquitecturas mediante backtesting histórico sobre el periodo 2019–2024, utilizando métricas financieras estándar como el ratio de Sharpe, el alpha, el drawdown máximo y el CAGR.

5. Comparar el rendimiento de las arquitecturas propuestas frente a estrategias de referencia basadas en señales cuantitativas y compra y mantenimiento.

1.3. Estructura del trabajo

El presente trabajo se organiza en ocho capítulos. El capítulo 2 revisa el estado del arte en inversión algorítmica, modelos de lenguaje aplicados a finanzas y sistemas multiagente. El capítulo 3 desarrolla los fundamentos teóricos necesarios para comprender el sistema propuesto: la arquitectura Transformer, el algoritmo Random Forest y los principales indicadores técnicos y métricas de evaluación de carteras.

El capítulo 4 describe el proceso de obtención y preprocesamiento de los datos utilizados, incluyendo los precios históricos de las 50 acciones seleccionadas y el dataset de noticias financieras FNSPID. El capítulo 5 presenta el diseño de las dos arquitecturas desarrolladas, el sistema LLM puro y el sistema híbrido, así como la definición de los perfiles de riesgo y las tecnologías utilizadas.

El capítulo 6 detalla la implementación de los módulos principales: los agentes especializados, el sistema de backtesting y la generación de señales mensuales. El capítulo 7 presenta y analiza los resultados obtenidos para las cuatro estrategias comparadas, con especial atención a las métricas de rentabilidad ajustada por riesgo. Finalmente, el capítulo 8 recoge las conclusiones del trabajo y las líneas de investigación futura.

Capítulo 2

Estado del arte

2.1. Sistemas de inversión algorítmica

La inversión algorítmica surge a finales del siglo XX con la automatización de las órdenes bursátiles y la proliferación de los mercados electrónicos. En sus primeras estapas, los sistemas se basaban en reglas deterministas derivadas del análisis técnico: cruce de medias móviles, niveles de soporte y resistencia, o umbrales del índice de fuerza relativa (RSI). Estos enfoques, aunque limitados, sentaron las bases de la negociación sistemática [5].

Con la llegada del aprendizaje automático, el paradigma cambió radicalmente. En lugar de programar reglas explícitas, los modelos aprenden patrones directamente de los datos históricos. Entre los algoritmos más adoptados destaca el Random Forest [6], un método de combinación de modelos basado en la combinación de múltiples árboles de decisión entrenados sobre subconjuntos aleatorios de datos y características. Su robustez frente al sobreajuste y su capacidad para manejar espacios de alta dimensionalidad lo han convertido en una referencia en la predicción de movimientos bursátiles. Krauss et al. [7] lo aplicaron junto con redes neuronales profundas y *gradient boosted trees* sobre los constituyentes del S&P 500, obteniendo retornos diarios significativos en un contexto de arbitraje estadístico.

Posteriormente, la irrupción del aprendizaje profundo abrió nuevas vías. Redes neuronales recurrentes, modelos LSTM y, más recientemente, arquitecturas basadas en Transformer han demostrado capacidad para capturar dependencias temporales complejas en series financieras [8]. Sin embargo, estos enfoques presentan limitaciones importantes: operan exclusivamente sobre datos estructurados de precio y volumen, ignoran información cualitativa como noticias o informes, y no adaptan su comportamiento al perfil del inversor. El libro de López de Prado [1] sistematiza muchas de estas técnicas advirtiendo además de los riesgos específicos del ML aplicado a finanzas, como la fuga de datos o el sobreajuste sobre series temporales.

El presente trabajo se sitúa en la siguiente generación de estos sistemas, incorporando modelos de lenguaje y análisis de sentimiento para superar las limitaciones de los enfoques puramente cuantitativos.

2.2. Modelos de lenguaje en finanzas

Los modeloss de lenguaje han transformado el procesamiento de texto financiero en los últimos años. Antes del uso de ellos, el análisis de noticias o de otro tipo de documento

financiero se basaba en grandes diccionarios de palabras a positivas y negativas como el de Loughran-McDonald, hechos para el dominio financiero pero limitados por su incapcidad de capturar contexto [9]. La arquitectura Transformer [2] y, en particular, el modelo BERT [10], supusieron un salto cualitativo. Por primera vez era posible representar el significado de una palabra en función de su contexto completo, no de forma aislada. Esto abrió la puerta a modelos especializados en finanzas. FinBERT [3] es el ejemplo más directo: un BERT preentrenado sobre noticias financieras, informes de resultados y documentos del mercado, que supera consistentemente a los enfoques basados en diccionarios en tareas de clasificación de sentimiento.

Recientemente, los modelos generativos de gran escala han dado un paso hacia adelante. Li et al. [9] hacen un repaso del estado de los LLM en finanzas, señalando que modelos como GPT pueden aplicarse sin entrenamiendo o dandoles simplemente un ejemplo de uso. Trabajos más recientes han extendido este enfoque a modelos de código abierto similares a Mistral 7B, demostrando que estrategias de inversión basadas en el sentimiento generado por LLM pueden superar ampliamente a los índices de referencia [11].

En este trabajo se combina el modelo FinBert para el análisis de sentimiento histórico sobre el dataset FNSPID, que es de noticias del sector; con Mistal 7B como orquestador de las decisiones finales. Esta separación de responsabilidades permite aprovechar la especialización de FinBERT en texto financiero y la capacidad de razonamiento de Mistral, sin incurrir en el coste computacional de usar un LLM de gran escala para cada tarea.

2.3. Sistemas multiagente

Los sistemas multiagente (MAS) son una rama de la inteligencia artificial en la que diferentes agentes autonomos interactúan con el fin de resolver problemas que niguno de ellos podría abordar de forma individual [4].Cada agente percibe su entorno, razona sobre él y actúa en consecuencia, pudiendo coordinarse con otros agentes mediante protocolos de comunicación.

La aparición de los LLM transformó este paradigma. Antes, los agentes se programaban con reglas explícitas o modelos estadísticos. Ahora es posible definir agentes los cuales su comportamiento se emerja del lenguaje natural: se les asigna un rol a través de un prompt y razonan sobre la información que reciben. Esto ha dado lugar a una nueva generación de sistemas multiagente basados en LLM aplicados a finanzas [12].

Un ejemplo representativo es TradingAgents [13], una plataforma donde agentes especializados en análisis fundamental, técnico y de sentimiento colaboran para generar decisiones de inversión. Cada agente procesa un tipo distinto de información y pasa su análisis a un agente superior que toma la decisión final, siguiendo una estructura jerárquica similar a la de un equipo de analistas real. Trabajos como FinCon [14] llevan este enfoque más lejos, organizando los agentes en relaciones manager-analista con comunicación en lenguaje natural.

El sistema propuesto en este trabajo sigue la misma línea, con cinco agentes especializados coordinados por un orquestador. La principal diferencia entre los trabajos mencionados es la decisión de sustituir cuatro de los cinco agentes LLM por modelos deterministas en la arquitectura híbrida, reduciendo en gran medida el coste computacional sin sacrificar la capacidad de razonamiento del orquestador.

2.4. Análisis de sentimiento financiero

El análisis de sentimiento financiero es una línea de investigación específica dentro del procesamiento del lenguaje natural que se centra en determinar si un texto financiero es positivo, negativo o es neutral sobre un activo o el mercado en general.

Antes de los modelos de lenguaje, el enfoque dominante eran los diccionarios especializados. Loughran y McDonald [15] construyeron uno de los más utilizados, diseñado específicamente para documentos financieros, donde palabras como *liability* o *risk* tienen connotaciones diferentes a las del lenguaje general. Estos diccionarios son sencillos y ágiles pero no capturan el contexto.

FinBERT [3] superó este enfoque al preentrenarse sobre noticias financieras, informes de resultados y documentos del mercado. En este trabajo se usa FinBert, sobre un dataset llamado FNSPID [16], del cual se descargaron al rededor de 160.000 noticias financieras en un periodo 2019–2024, para generar señales de sentimiento históricas.

Capítulo 3

Fundamentos teóricos

3.1. Arquitectura Transformer y LLMs

La arquitectura Transformer, propuesta por Vaswani et al. [2],ha supuesto una revolución en el procesamiento del lenguaje natural. Antes de su aparación, los modelos de lenguaje se basaban en redes recurrentes (RNN) y Long Short-Term Memory, que procesaban el tecto secuencialmente, palabra a palabra, lo que limitaba en gran medida su capacidad para capturar dependencias a larga distancia y dificultaba el entrenamiento paralelo.

El Transformer resolvió esto con el mecanismo de *atención*, el cual calcula la importancia de cada palabra respecto a todas las demás simultáneamente. Dado un texto de entrada, cada token genera tres vectores diferentes, consulta, clave y valor; y la atención se calcula como:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{3.1}$$

donde Q, K y V son las matrices de consultas, claves y valores, y d_k es la dimensión de los vectores. Este mecanismo permite al modelo aprender qué palabras son relevantes entre sí en función del contexto, independientemente de su distancia en el texto.

Los modelos de lenguaje de gran escala (LLM) son Transformers entrenados sobre enormes corpus de texto mediante la predicción del siguiente token. Con suficientes parámetros y datos, estos modelos desarrollan capacidades emergentes de razonamiento, traducción y generación de texto que no fueron programadas explícitamente.

En este trabajo como LLM se usa Mistral 7B [17], un modelo de 7.000 millones de parámetros desarollado por Mistral AI y publicado bajo licencia Apache 2.0, que es una licencia de software libre la cual da una gran libertad en el uso del software. Además, Mistral 7B supera a Llama 2 13B en todos los benchmarks evaluados, siendo Llama 2 13B el modelo de referencia de código abierto del momento en el que se publico, a pesar de tener casi la mitad de parámetros; e introduce dos optimizaciones clave: *grouped-query attention* (GQA) para acelerar la inferencia, y *sliding window attention* (SWA) para manejar secuencias largas con menor coste computacional. Su elección frente a alternativas como GPT-4 responde a tres criterios: es de código abierto, puede ejecutarse localmente sin coste de API, y cabe en hardware de consumo mediante cuantización.

3.2. Random Forest y métodos ensemble

El Random Forest es un método de aprendizaje automático que se basa en el concepto de combinación de modelos: en lugar de entrenar un solo modelo, se entrenan múltiples modelos débiles y se combinan sus predicciones para obterner una una predicción final más robusta. Fue proupuesta por el matemámatico estadounidende Leo Breiman [6] y se basa en dos ideales fundamentales: el *bagging* y la aleatorización de características.

El *bagging* consiste en entrenar cada árbol de decisión sobre una muestra aleatoria del conjunto de entrenamiento con reemplazamiento. Esto significa que cada árbol ve una versión ligeramente distinta de los datos, lo que reduce la correlación entre árboles y disminuye la varianza del modelo final. Además, en cada nodo de cada árbol solo se considera un subconjunto aleatorio de características para decidir la división óptima, lo que añade diversidad adicional al conjunto.

La predicción final se obtiene por votación mayoritaria en clasificación; cada árbol vota por una clase y gana la más votada, o por promedio en regresión. Este mecanismo hace al Random Forest especialmente robusto frente al sobreajuste, incluso con espacios de características de alta dimensionalidad [7].

Una ventaja adicional relevante para este trabajo es la importancia de características como la importancia de variables: el modelo calcula automáticamente qué variables contribuyen más a las predicciones, lo que permite interpretar qué indicadores técnicos o de riesgo son más determinantes en las señales de inversión.

3.3. Indicadores técnicos financieros

Los indicadores técnicos son cálculos matemáticos aplicados sobre el precio y el volumen histórico de un activo con el objetivo de detectar patrones y tendencias en el comportamiento de este activo. En este trabajo se utilizan tres indicadores clásicos como entrada para los modelos.

3.3.1. Índice de Fuerza Relativa (RSI)

El RSI fue propuesto por Wilder [18] y mide la velocidad y la magnitud de los movimientos de precio en un periodo determinando de n días, generalmente 14. Se calcula como:

$$RSI = 100 - \frac{100}{1 + RS}, \quad RS = \frac{\text{Media ganancias}_n}{\text{Media pérdidas}_n} \tag{3.2}$$

El RSI toma valores entre 0 y 100. Un valor por encima de 70 indica que el activo está sobrecomprado (el precio ha subido demasiado rápido y podría corregir); mientras que si tiene un valor por debajo de 30 indica sobreventa. En el sistema, el agente técnico interpreta estos umbrales para generar señales de venta o compra respectivamente.

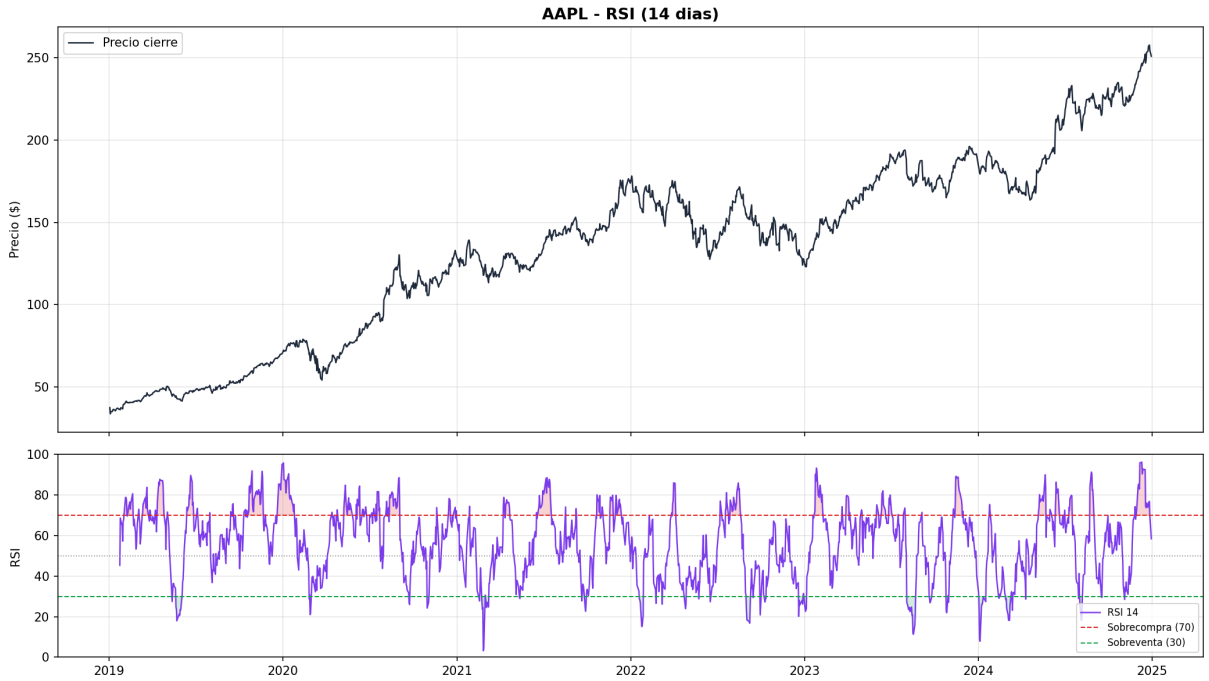


Figura 3.1: RSI de 14 periodos aplicado sobre AAPL (2019–2024). Las zonas sombreadas en rojo indican periodos de sobrecompra (RSI > 70).

3.3.2. MACD

El MACD (*Moving Average Convergence Divergence*) mide la diferencia entre dos medias móviles exponenciales del precio de cierre, habitualmente de 12 y 26 periodos:

$$MACD = EMA_{12} - EMA_{26} \tag{3.3}$$

Se calcula también una línea de señal como la media móvil exponencial del MACD de 9 periodos. Cuando el MACD cruza por encima de la línea de señal se interpreta como una señal alcista, y cuando cruza por debajo como bajista. El histograma ,diferencia entre MACD y señal, permite visualizar la fuerza de la tendencia.

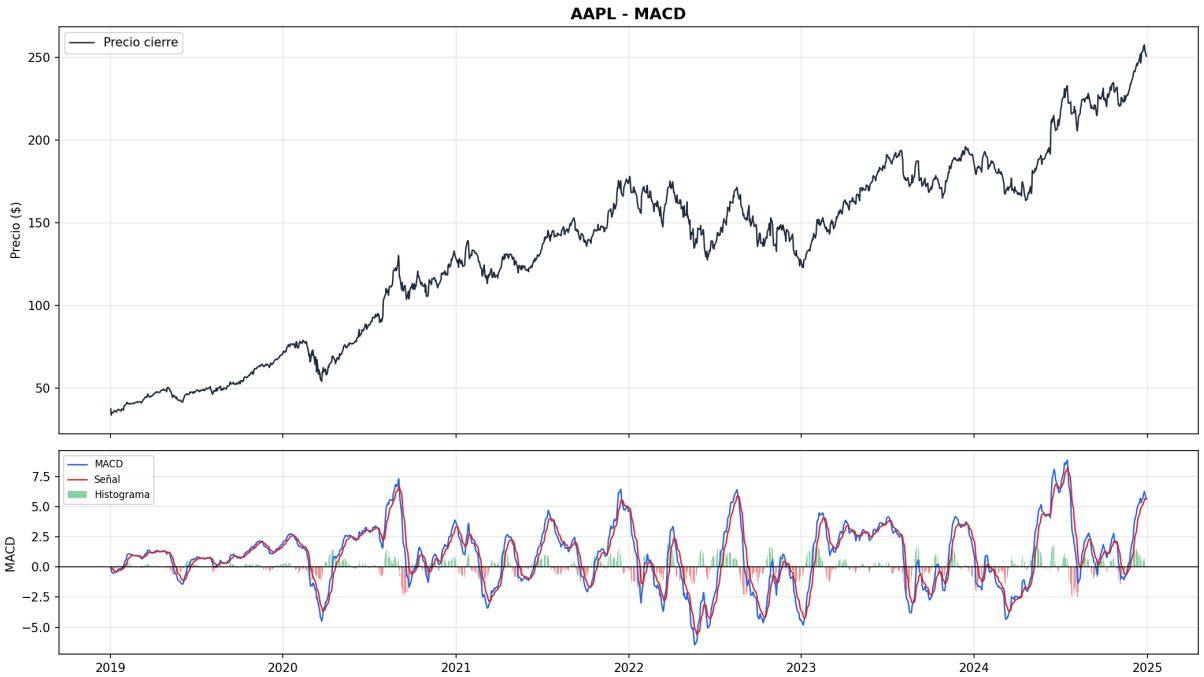


Figura 3.2: MACD aplicado sobre AAPL (2019–2024). En azul la línea MACD, en rojo la línea de señal y en verde el histograma.

3.3.3. Bandas de Bollinger

Las Bandas de Bollinger [19] se construyen a partir de una media móvil simple de n periodos y una banda superior e inferior separadas por k desviaciones estándar:

$$BB_{upper} = SMA_n + k \cdot \sigma_n, \quad BB_{lower} = SMA_n - k \cdot \sigma_n \tag{3.4}$$

donde σ_n es la desviación estándar del precio en los últimos n días. Habitualmente se usan $n = 20$ y $k = 2$. Cuando el precio toca la banda superior el activo está sobrecomprado, y cuando toca la inferior está sobrevendido. En este trabajo se utiliza el porcentaje de Bollinger ($BB\,\%$), que normaliza la posición del precio dentro de las bandas entre 0 y 1:

$$BB\,\% = \frac{Precio - BB_{lower}}{BB_{upper} - BB_{lower}} \tag{3.5}$$

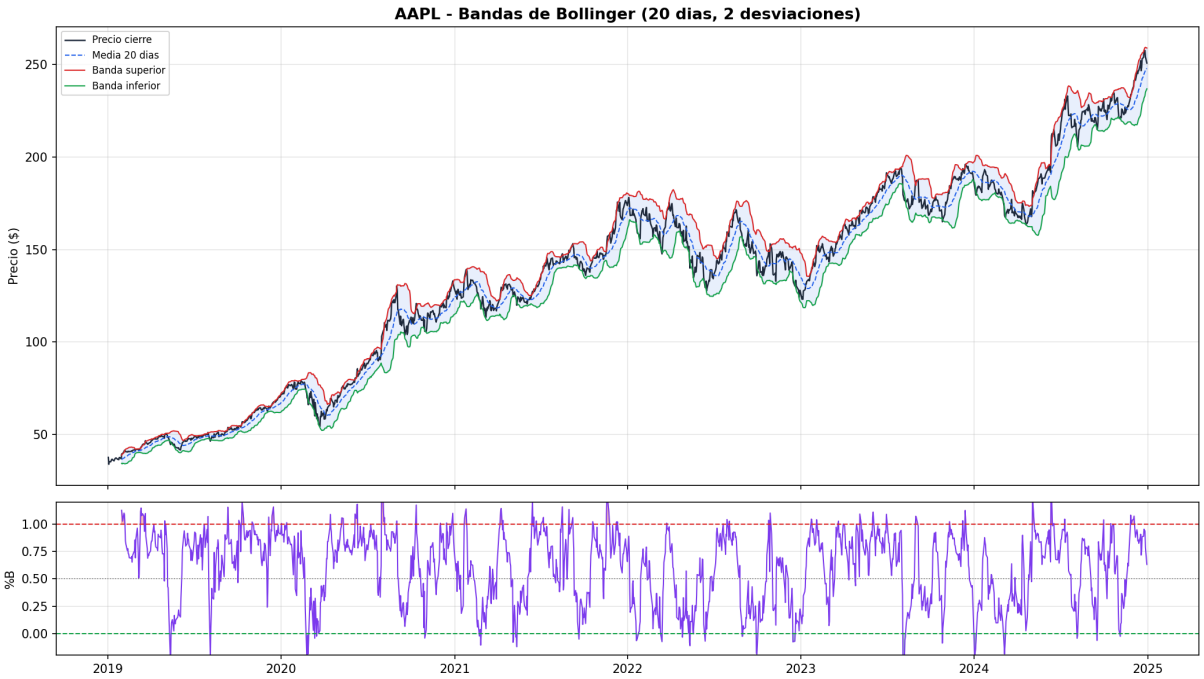


Figura 3.3: Bandas de Bollinger (20 días, 2 desviaciones) sobre AAPL (2019–2024). El panel inferior muestra el $BB\,\%$.

3.4. Métricas de evaluación de carteras

Las métricas de evaluación de carteras permiten cuantificar el rendimiento de una estrategia de inversión de forma objetiva. En este proyecto se usan las siguientes métricas sobre los resultados del backtesting

3.4.1. Retorno total y CAGR

El retorno total mide el crecimiento absoluto de la cartera en el periodo evaluado:

$$R_{total} = \frac{V_{final} - V_{inicial}}{V_{inicial}} \times 100 \tag{3.6}$$

El CAGR (*Tasa de crecimiento anual compuesto*) nos muestra el retorno como una tasa anual equivalente, permitiendo comparar diferentes estrategias con distintos horizontes temporales:

$$CAGR = \left(\frac{V_{final}}{V_{inicial}}\right)^{\frac{1}{n}} - 1 \tag{3.7}$$

donde n es el número de años del periodo evaluado.

3.4.2. Ratio de Sharpe y Sortino

La volatilidad anualizada mide la dispersión de los retornos diarios de la cartera y cuantifica el riesgo asumido:

$$\sigma_{anual} = \sigma_{diaria} \times \sqrt{252} \tag{3.8}$$

donde σ_{diaria} es la desviación estándar de los retornos diarios. Una volatilidad alta indica mayor riesgo; una baja indica que la cartera evoluciona de forma más estable.

El ratio de Sharpe [20] mide la rentavilidad por unidad de riesgo asumido, donde el riesgo se mide ocmo la volatilidad de los retornos diarios:

$$Sharpe = \frac{\bar{r} - r_f}{\sigma} \times \sqrt{252} \tag{3.9}$$

donde $\bar{r}$ es el retorno medio diario, r_f es la tasa libre de riesgo diaria y σ es la desviación estándar de los retornos diarios. El factor $\sqrt{252}$ anualiza el ratio. Un valor superior a 1 se considera bueno y superior a 2 excelente.

El ratio de Sortino es una variante que penaliza solamente la volatilidad negativa, considerando más justo que las subidas no penalicen al modelo:

$$Sortino = \frac{\bar{r} - r_f}{\sigma_{neg}} \times \sqrt{252} \tag{3.10}$$

donde σ_{neg} es la desviación estándar calculada solo sobre los retornos negativos

3.4.3. Alpha, Beta y drawdown máximo

La Beta mide la sensibilidad de la cartera respecto al mercado de referncia (SPY):

$$\beta = \frac{Cov(r_p, r_m)}{Var(r_m)} \tag{3.11}$$

donde r_p son los retornos de la cartera y r_m los del mercado. Un valor de $\beta = 1$ indica que la cartera se mueve igual que el mercado, mientras que $\beta < 1$ indica menor sensibilidad.

El Alpha,el cual está basado en el modelo CAPM [20], mide la rentavilidad ganada sobre la esperada dado el riesgo asumido:

$$\alpha = r_p - [r_f + \beta \cdot (r_m - r_f)] \tag{3.12}$$

Un alpha positivo significa que la estrategia gana más de lo que le correspondería por el simple hecho de estar expuesta al mercado. Es decir, los agentes añaden valor real.

El drawdown máximo mide la mayor caída desde un máximo histórico hasta el siguiente mínimo, mostando el peor escenario que habría vivido un inversor:

$$MaxDD = \min_t \frac{V_t - \max_{s \le t} V_s}{\max_{s \le t} V_s} \tag{3.13}$$

La figura 3.4 ilustra el drawdown histórico de AAPL durante el periodo 2019–2024. Se aprecian claramente los dos periodos de mayor caída: el crash de marzo de 2020 por la pandemia de COVID-19, con un drawdown cercano al $-30\,\%$, y la corrección de 2022, donde la acción perdió más del $25\,\%$ desde su máximo anterior.

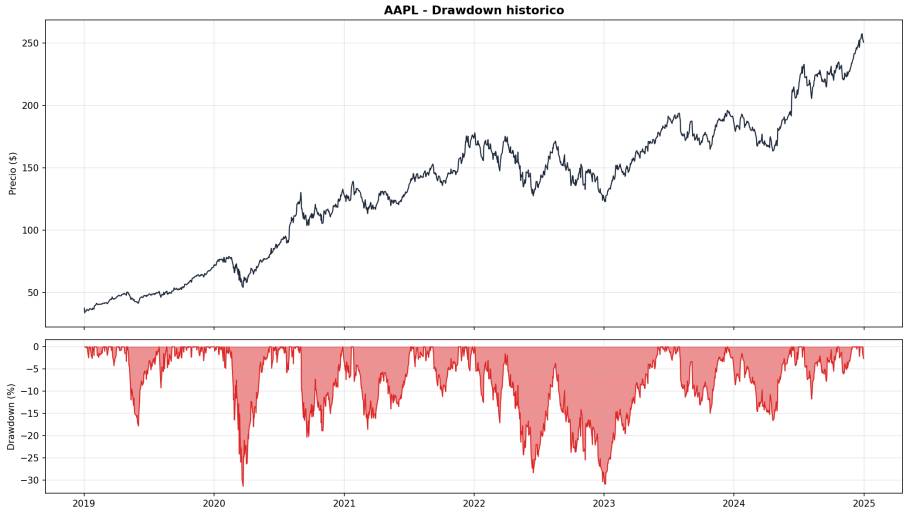


Figura 3.4: Drawdown histórico de AAPL (2019–2024).

3.4.4. Information Ratio

El Information Ratio mide la rentabilidad generada por encima del benchmark por unidad de *tracking error*, error de seguimiento, es decir, por unidad de desviación respecto al índice de referencia:

$$IR = \frac{r_p - r_b}{TE}, \quad TE = \sigma(r_p - r_b) \times \sqrt{252} \tag{3.14}$$

donde r_p es el retorno de la cartera, r_b el retorno del benchmark y TE el error de seguimiento anualizado. Un IR positivo indica que la estrategia genera rentabilidad extra de forma consistente respecto al índice; un IR negativo indica lo contrario.

Capítulo 4

Datos y preprocesamiento

4.1. Selección de activos

El índice S&P 500 agrupa las 500 empresas de mayor capitalización bursátil de Estados Unidos, representando alrededor del 80 % del mercado de renta variable estadounidense. Se planteo la opción de trabajar con las 500 acciones del indice, pero el coste computacional no era asumible para el hardware disponible, y menos para hacer un backtesting histórico.

Por ello se seleccionó un subconjunto de 50 acciones atendiendo a dos criterios principales: la disponibilidad de datos históricos sobre el precio y noticias financieras, y representatividad sectorial. Las acciones se distribuyeron entre seis sectores: tecnología, salud, financiero, consumo, energía e industrial; para evitar una cocentración excesiva en algun sector y tratar de garantizar que el sistema fuera evaluado en distintas condiciones de mercado.

La lista completa de tickers seleccionados se recoge en el apéndice B.

4.2. Datos de precio histórico

Los datos del precio historico se obtuvieron a través de la librería `yfinance` de Python, que proporciona de forma gratuita a los datos históricos de Yahoo Finance.

- **2019–2024**: periodo principal de backtesting, con aproximadamente 1.500 sesiones de mercado por ticker.
- **2010–2018**: periodo de entrenamiento de los modelos Random Forest, con aproximadamente 2.250 sesiones adicionales.

Los datos se almacenaron en formato `parquet` mediante la librería `pyarrow`, que reduce significativamente el almacenamiento que ocupa en disco respecto a formato CSV y acelera la carga en memoria al de cada sesión de trabajo. El precio usado para calcular todas los indicadores y metricas es el precio de cierre ajustado, que tiene en cuenta dividendos y particiones de acciones para que los precios sean comparables a lo largo del tiempo.

4.3. Dataset de noticias financieras: FNSPID

Para el análisis de sentimiento histórico se utilizó el dataset FNSPID [16] (*Financial News and Stock Price Integration Dataset*), descargado desde la web HuggingFace. El

dataset contiene 159.997 noticias financieras del periodo 2019–2024, asociadas a los tickers del S&P 500 mediante su símbolo bursátil.

Los dos tickers sin cobertura son META y HON. En el caso de META, se buscó tanto bajo su ticker actual como bajo FB, nombre con el que cotizaba antes de octubre de 2021, pero el dataset no contiene noticias bajo ninguno de los dos símbolos. Para estos dos tickers, y para cualquier fecha posterior al 9 de enero de 2024, último día con datos en el dataset, se utiliza una alternativa basada en el precio: si el precio ha subido en los últimos 5 y 20 días de negociación se interpreta como tendencia positiva, y si ha bajado como negativa.

4.4. Análisis exploratorio

Antes de diseñar el sistema se realizó un análisis exploratorio de los datos para comprender el comportamiento de las 50 acciones seleccionadas durante el periodo 2019-2024.

La figura 4.1 muestra la evolución normalizada del precio por sector (base 100 = enero 2019). El sector tecnológico destaca claramente sobre el resto, con el caso más sorprendente de NVDA, y con apenas un único caso de retorno 0 o negativo, siendo este INTC.

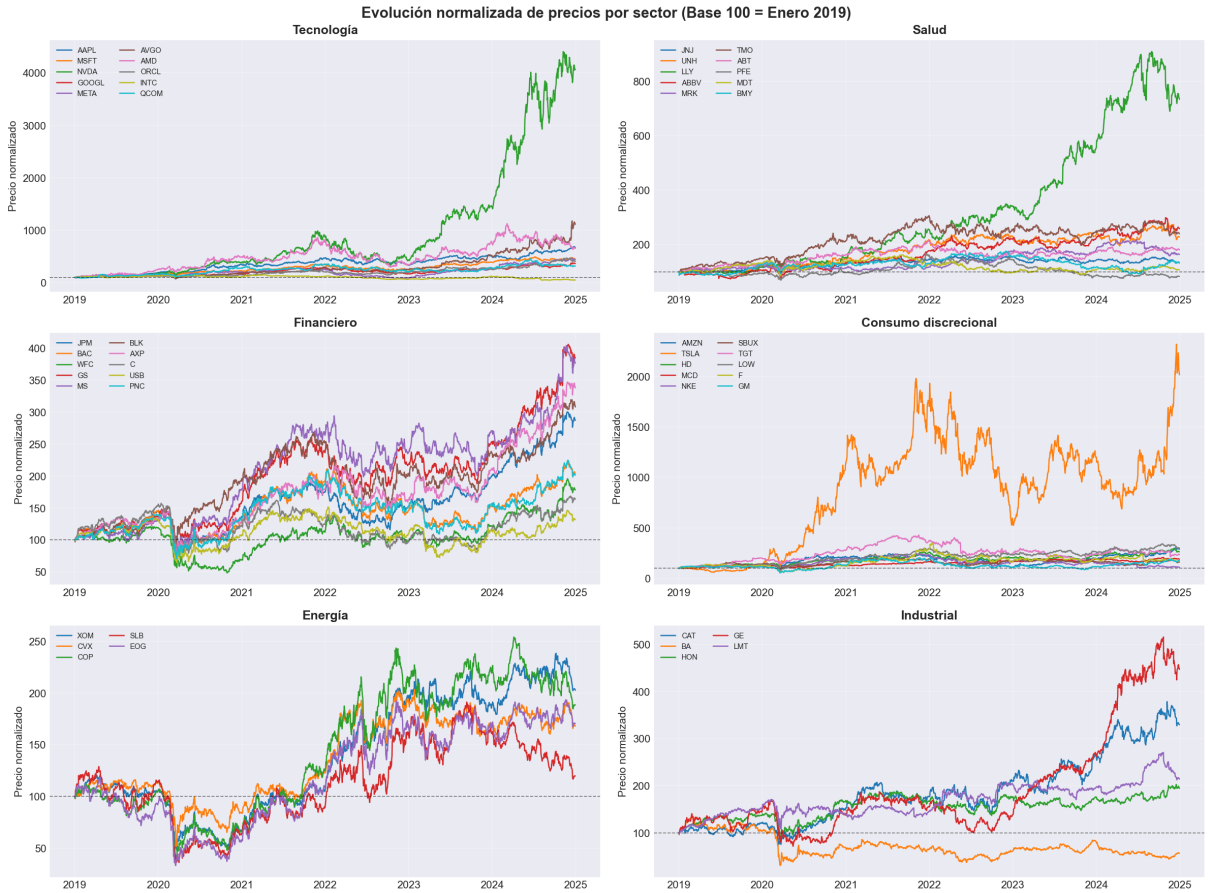


Figura 4.1: Evolución normalizada de precios por sector (Base 100 = enero 2019).

La figura 4.2 muestra la distribución de retornos diarios de una muestra representativa de acciones. Todas presentan una distribución aproximadamente normal centrada en cero, con colas largas que reflejan eventos extremos; especialmente el crash de marzo de 2020

por la pandemia de COVID-19. TSLA y NVDA muestran mayor dispersión, coherente con su mayor volatilidad.

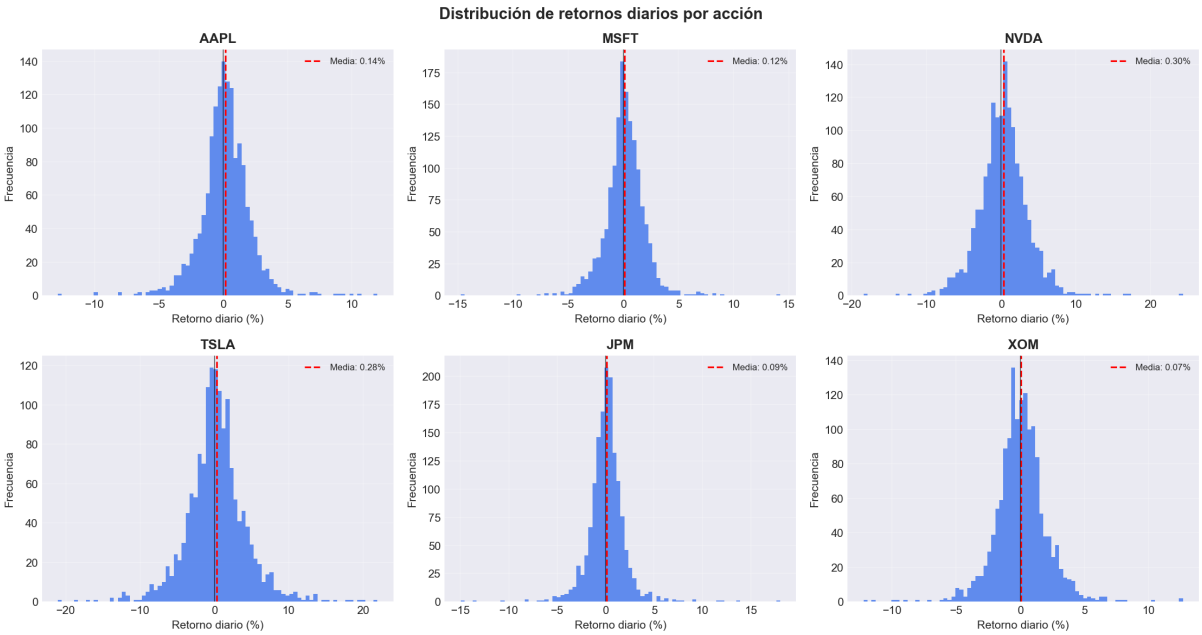


Figura 4.2: Distribución de retornos diarios por acción.

La figura 4.3 muestra la matriz de correlaciones de retornos diarios entre las 50 acciones. Se observan bloques de alta correlación dentro de cada sector; especialmente en el financiero (JPM, BAC, WFC, GS, MS) y en energía (XOM, CVX, COP); mientras que la correlación entre sectores es moderada. Esta estructura justifica la diversificación sectorial adoptada en la selección de activos.

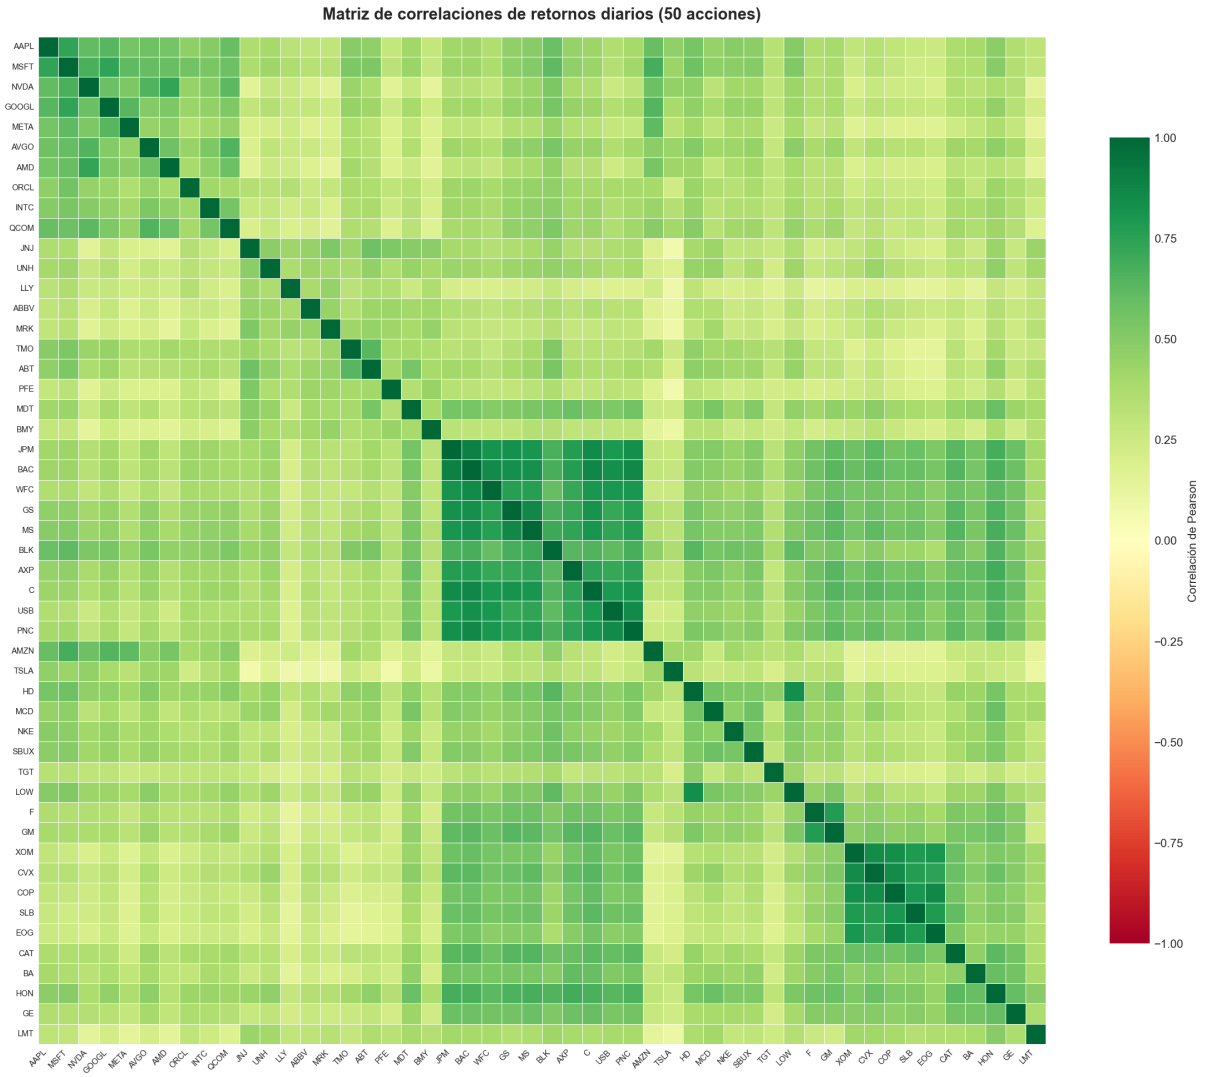


Figura 4.3: Matriz de correlaciones de retornos diarios (50 acciones).

Finalmente, la figura 4.4 presenta el mapa riesgo-rentabilidad anualizado. Se aprecia una relación positiva general entre volatilidad y retorno, aunque con excepciones notables: NVDA y AVGO ofrecen alta rentabilidad con volatilidad moderada, mientras que TSLA concentra el mayor riesgo del conjunto. PFE e INTC son los únicos con retornos próximos a cero o negativos.

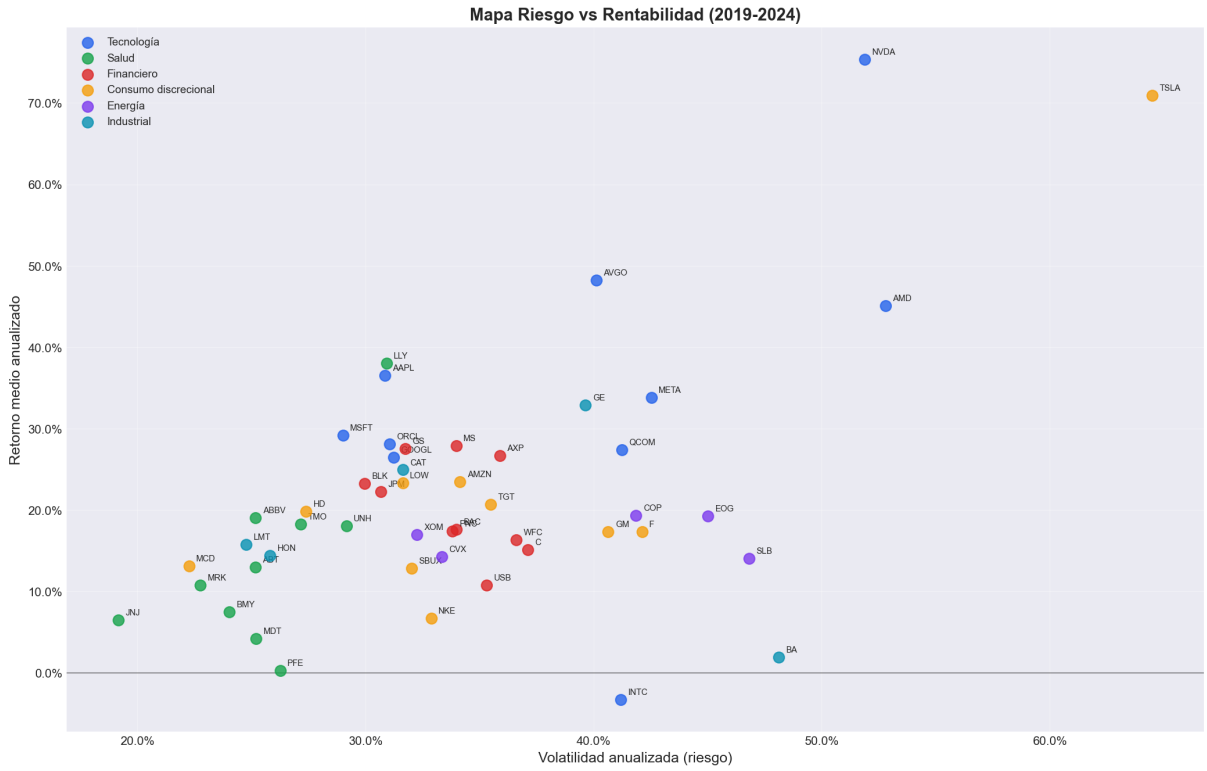


Figura 4.4: Mapa riesgo vs rentabilidad anualizado (2019–2024).

Capítulo 5

Diseño del sistema

5.1. Arquitectura general

El sistema se organiza en torno a cinco agentes especializados y un orquestador. Cada agente analiza un dominio concreto del activo; el análisis técnico, el fundamental, el riesgo, el sentimiento y la simulación estocástica; y devuelve una señal independiente con un nivel de confianza del 1 al 10. El orquestador recibe las cinco señales y toma la decisión final ponderando su importancia según el perfil de riesgo del inversor.

Este diseño sigue el principio de separación de responsabilidades: cada agente es experto en su dominio y no conoce el perfil del inversor, lo que garantiza que sus señales sean objetivas e independientes entre sí. Solo el orquestador conoce el perfil y aplica los criterios de selección correspondientes.

Se han diseñado e implementado dos versiones de esta arquitectura que se describen en las secciones siguientes y se evalúan comparativamente en el capítulo 7.

5.2. Sistema LLM puro

El sistema LLM puro emplea Mistral 7B como motor de decisión. Su funcionamiento difiere según el modo de operación: en tiempo real utiliza cinco agentes especializados coordinados por un orquestador, mientras que en el backtesting histórico se emplea una arquitectura simplificada por razones de viabilidad computacional.

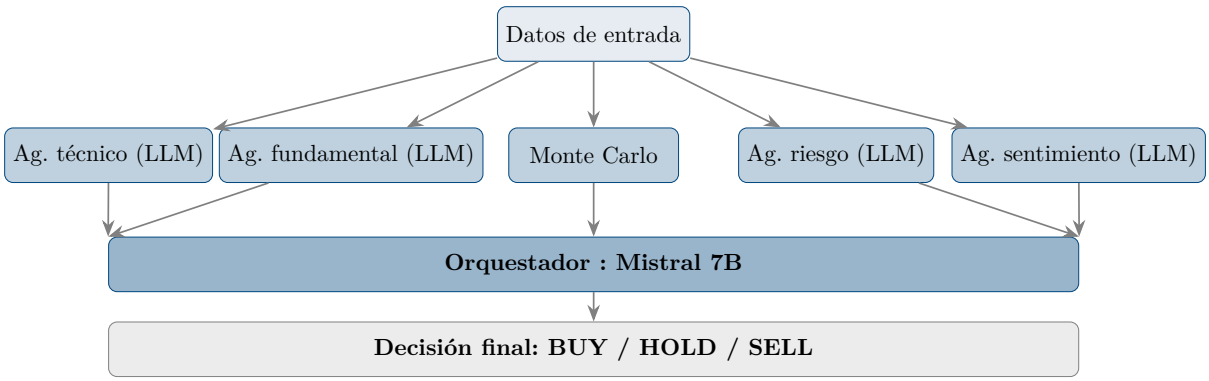


Figura 5.1: Arquitectura del sistema LLM puro: cinco agentes coordinados por un orquestador.

5.2.1. Agentes especializados

Cada agente recibe los datos de su dominio en forma de texto compacto y devuelve un objeto `SenalInversion` con tres campos: la decisión (BUY, HOLD o SELL), la confianza (1–10) y una justificación de máximo 15 palabras. Los cinco agentes son:

- **Agente técnico**: analiza RSI, MACD, Bandas de Bollinger y medias móviles.
- **Agente fundamental**: analiza ratios financieros obtenidos de Yahoo Finance; P/E, ROE, crecimiento de ingresos, deuda y margen de beneficio.
- **Agente de riesgo**: analiza volatilidad anualizada, ratio de Sharpe, VaR al 95 %, drawdown máximo, beta y alpha.
- **Agente de sentimiento**: analiza titulares de noticias obtenidos de Yahoo Finance en tiempo real.
- **Agente Monte Carlo**: ejecuta 1.000 simulaciones de precio a 20 días. La decisión es determinista: BUY si la probabilidad de subida supera el 60 %, SELL si es inferior al 40 %, y HOLD en caso contrario.

5.2.2. Salida estructurada con Pydantic

Un problema habitual al usar LLMs en sistemas automáticos es que la salida es texto libre, lo que hace el sistema frágil ante variaciones en el formato de respuesta. Para resolverlo se usa LangChain con salida estructurada mediante Pydantic: se define un esquema con tipos y restricciones, LangChain instruye a Mistral para que responda en formato JSON válido según ese esquema y valida automáticamente la respuesta. Si Mistral devuelve algo inválido, LangChain reintenta la llamada.

```
        class SenalInversion(BaseModel):
        ticker: str
        decision: Literal["BUY", "HOLD", "SELL"]
        confianza: int = Field(ge=1, le=10)
        justificacion: str

        class DecisionFinal(BaseModel):
        ticker: str
        decision: Literal["BUY", "HOLD", "SELL"]
        confianza: int = Field(ge=1, le=10)
        resumen_agentes: str
        justificacion: str
```

Listing 5.1: Modelos Pydantic del sistema LLM puro

En concreto, LangChain cumple tres funciones en este sistema: gestiona la conexión con Ollama mediante `ChatOllama`, que abstrae las peticiones HTTP al servidor local donde corre Mistral; aplica la salida estructurada mediante `with_structured_output()`, que instruye al modelo para responder en el formato JSON definido por Pydantic; y gestiona los reintentos automáticos cuando la respuesta no supera la validación del esquema.

El orquestador recibe las cinco señales y el perfil del inversor y toma la decisión final. Es el único agente que conoce el perfil; los demás agentes operan de forma objetiva e independiente. El prompt incluye las cinco señales con su decisión, confianza y justificación,

y Mistral devuelve un objeto `DecisionFinal` con la decisión final, un resumen de las señales y una justificación breve.

5.2.3. Backtesting histórico: arquitectura simplificada

Ejecutar el sistema completo de cinco agentes sobre 50 acciones durante 72 meses habría supuesto más de 21.000 llamadas al LLM, lo que era inviable, debido a al hardware limitado (GPU NVIDIA RTX3060 laptop). Por ello, el backtesting histórico emplea una arquitectura simplificada mediante la función `generar_senales_mensuales()` del notebook de backtesting.

El flujo es el siguiente: por cada mes del periodo 2019–2024, se calculan los indicadores técnicos (RSI, MACD, Bollinger) de cada acción hasta la fecha fin del mes, evitando *look-ahead bias*. Las 50 acciones se dividen en grupos de 5 y por cada grupo se construye un prompt con los indicadores de las cinco acciones. Mistral recibe ese prompt y devuelve una señal BUY, HOLD o SELL para cada una mediante `SenalBatch`. Las señales se guardan en CSV con checkpoint para poder reanudar si el proceso se interrumpe.

En este modo Mistral actúa como un analista técnico puro: interpreta los indicadores en lenguaje natural y decide. No intervienen el agente fundamental, el de riesgo, el de sentimiento ni el Monte Carlo. La diferencia respecto a las señales cuantitativas puras es que las reglas de decisión las infiere Mistral del contexto del prompt en lugar de aplicar umbrales fijos.

Cabe destacar que el tratamiento de la señal HOLD y la gestión del capital en cartera responden a decisiones de diseño específicas que se detallan en la sección 6.5.1.

5.3. Sistema híbrido

El sistema híbrido surge como respuesta a las limitaciones del sistema LLM puro: seis llamadas a Mistral por acción suponen un tiempo de procesamiento elevado y resultados no deterministas. La arquitectura híbrida sustituye cuatro de los cinco agentes LLM por modelos especializados más rápidos y reproducibles, reservando Mistral únicamente para la orquestación final. Esto reduce las llamadas al LLM de seis a una por acción, lo que genera el poder hacer un backtesting usando todos los agentes.

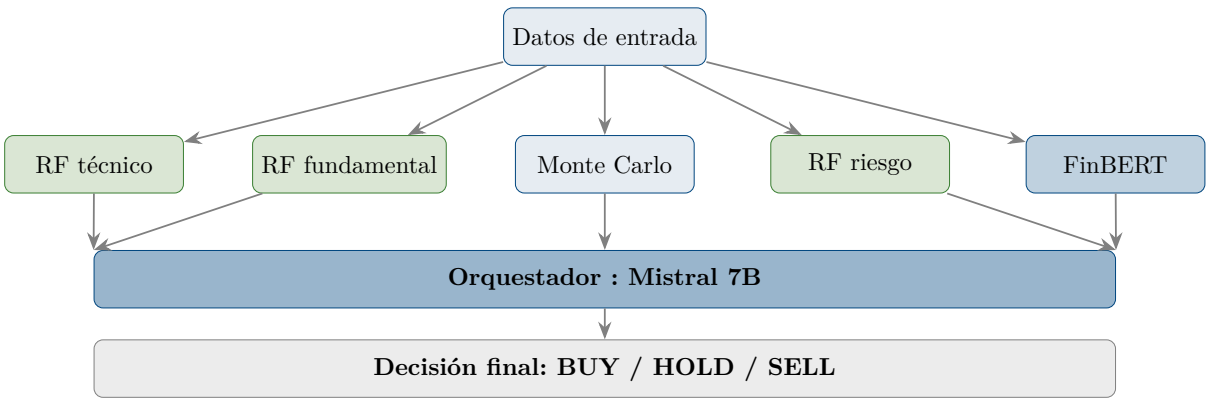


Figura 5.2: Arquitectura del sistema híbrido: tres Random Forest, FinBERT y Monte Carlo coordinados por Mistral 7B.

5.3.1. Random Forest especializados

Se entrenan tres Random Forest independientes, uno por dominio de análisis. Cada uno recibe únicamente las características de su dominio. Las características por dominio son:

- **RF técnico**: RSI, MACD, señal MACD, histograma MACD, $BB\,\%$, ratios precio/SMA20, precio/SMA50 y precio/SMA200, retorno a 1 y 5 días.
- **RF fundamental**: retornos a 60, 120 y 252 días, ratio SMA50/SMA200 (indicador de *golden/death cross*), volatilidad anualizada a 252 días y RSI. Se usan características de precio a largo plazo como aproximación a la salud empresarial relativa, dado que yfinance no proporciona series temporales de ratios fundamentales de forma gratuita.
- **RF de riesgo**: volatilidad a 20 y 60 días, ratio de Sharpe a 60 días, drawdown máximo a 60 días, beta, VaR al 95 % a 20 días y retorno a 20 días.

La etiqueta de entrenamiento se define como BUY si el retorno a 20 días supera el 5 %, SELL si cae más del 5 %, y HOLD en caso contrario. El entrenamiento usa datos del periodo 2010–2018 y la evaluación sobre 2019–2024, con `TimeSeriesSplit` para la validación cruzada y `GridSearchCV` para la búsqueda de hiperparámetros. La probabilidad máxima de clase devuelta por el RF se convierte directamente en el nivel de confianza de la señal (escala 0–1 mapeada a 1–10).

5.3.2. Agente de sentimiento FinBERT

El análisis de sentimiento se realiza con FinBERT (`ProsusAI/finbert`), un modelo BERT de 110 millones de parámetros preentrenado sobre texto financiero. Se ejecuta en CPU mediante el pipeline de HuggingFace con carga diferida (*lazy loading*), lo que libera la GPU para Mistral.

Para cada acción y fecha se recuperan hasta cinco titulares del dataset FNSPID en una ventana de 7 días anterior a la fecha de la señal. Los titulares se procesan en batch en una sola llamada al pipeline. FinBERT clasifica cada titular como positivo, negativo o neutro con una probabilidad asociada, y la puntuación neta se calcula como:

$$score = \frac{1}{n} \sum_{i=1}^{n} p_i \cdot s_i, \quad s_i \in \{+1, 0, -1\} \tag{5.1}$$

donde p_i es la probabilidad del titular i y s_i vale $+1$, 0 o -1 según sea positivo, neutro o negativo. Una puntuaci'on superior a 0,15 genera señal BUY, inferior a $-0{,}15$ genera SELL, y el rango intermedio genera HOLD. Para los tickers sin cobertura en FNSPID (META y HON) y para fechas posteriores al 9 de enero de 2024, la lista de titulares queda vacía y la señal resultante es HOLD con confianza baja.

5.3.3. Simulación Monte Carlo

El agente Monte Carlo es idéntico en ambas arquitecturas y no interviene ningún modelo de aprendizaje automático. Ejecuta 1.000 simulaciones de precio mediante movimiento browniano geométrico a 20 días de horizonte temporal. La decisión es puramente matemática con los mismos umbrales del 60 % y 40 %. Para el backtesting, los parámetros de la simulación se calculan únicamente con datos anteriores a la fecha de la señal, evitando *look-ahead bias*.

5.3.4. Orquestador Mistral

El orquestador del sistema híbrido recibe las cinco señales en formato compacto y toma la decisión final. El prompt se diseñó reducido para minimizar los tokens de entrada y el tiempo de respuesta:

```
Gestor de cartera. Perfil: {descripcion_perfil}
Senales: Tech:BUY(7) Fund:HOLD(5) Risk:BUY(6) Sent:BUY
   (8) MC:HOLD(4)
Decide BUY, HOLD o SELL segun el perfil.
Justifica en maximo 10 palabras en espanol.
```

Listing 5.2: Prompt del orquestador en el sistema híbrido

Para evitar alucinaciones en el campo ticker, el esquema de Pydantic se divide en dos clases: `_DecisionLLM`, que rellena Mistral con solo decisión, confianza y justificación; y `DecisionFinal`, donde Python asigna el ticker directamente sin intervención del LLM. Además se limita la generación a 120 tokens mediante el parámetro `num_predict` de Ollama, lo que redujo el tiempo de respuesta de aproximadamente 370 segundos por acción a unos 8 segundos.

5.4. Perfiles de riesgo

El sistema adapta las decisiones de inversión al tipo de inversor mediante tres perfiles de riesgo: conservador, moderado y agresivo. Cada perfil define dos parámetros que condicionan la selección final de activos en cartera:

- **Confianza mínima**: umbral por debajo del cual una señal BUY se descarta. Un inversor conservador solo acepta señales con alta confianza, mientras que uno agresivo acepta cualquier señal positiva.
- **Máximo de posiciones simultáneas**: número máximo de acciones que pueden estar en cartera al mismo tiempo. Limita la exposición al mercado y determina cómo se distribuye el capital.

Los valores concretos de cada perfil se recogen en la tabla 5.1.

Tabla 5.1: Parámetros de los perfiles de riesgo

Perfil	Confianza mínima	Máx. posiciones
Conservador	7/10	5
Moderado	5/10	10
Agresivo	3/10	15

El perfil conservador es el más restrictivo: solo actúa cuando el sistema tiene alta convicción y limita la cartera a 5 posiciones, lo que resulta en periodos prolongados fuera del mercado. El perfil agresivo acepta cualquier señal con confianza mínima y puede mantener hasta 15 posiciones simultáneas, maximizando la exposición. El moderado equilibra ambos extremos.

Es importante destacar que estos parámetros son los mismos para ambas arquitecturas, lo que garantiza que las diferencias de rendimiento observadas en el backtesting sean atribuibles a la calidad de las señales y no a una configuración diferente de los perfiles.

5.5. Tecnologías utilizadas

El sistema se ha desarrollado íntegramente en Python 3.12 sobre un entorno de Jupyter Notebook. La tabla 5.2 recoge las principales librerías utilizadas.

Tabla 5.2: Tecnologías utilizadas en el sistema

Librería	**Versión**	**Uso**
yfinance	1.2.0	Descarga de datos de precio y noticias
pandas	2.2.3	Procesamiento de series temporales
numpy	1.26.4	Cálculos numéricos
scikit-learn	1.5.2	Random Forest, GridSearchCV, TimeSeriesSplit
langchain-ollama	1.1.0	Conexión con Ollama y salida estructurada
langchain-core	1.3.0	Abstracción de modelos y prompts
pydantic	2.12.5	Validación de salidas estructuradas
transformers	5.7.0	Pipeline de FinBERT
torch	2.11.0	Backend de FinBERT (CPU)
pyarrow	23.0.1	Formato parquet para almacenamiento
matplotlib	3.8.2	Visualización de resultados
joblib	1.4.2	Serialización de modelos RF

El modelo LLM utilizado es `mistral:7b-instruct-v0.3-q4_0`, ejecutado localmente mediante Ollama sobre una GPU NVIDIA RTX 3060 de 6 GB de VRAM. La cuantización a 4 bits reduce el tamaño del modelo de aproximadamente 14 GB a 4 GB sin una pérdida significativa de calidad, haciéndolo viable en hardware de consumo. FinBERT corre en paralelo sobre CPU, liberando la GPU íntegramente para Mistral.

Capítulo 6

Implementación

6.1. Implementación del sistema LLM puro

El sistema LLM puro se implementa en un único módulo Python, `sistema_llm_puro.py`, que concentra las herramientas de cálculo, los agentes especializados y las funciones de orquestación. Esta decisión de diseño responde al carácter de prototipo de investigación del sistema: mantener toda la lógica en un único archivo facilita la reproducibilidad, ya que cualquier notebook puede importar el sistema completo con una sola instrucción, y elimina dependencias entre módulos que añadirían complejidad sin beneficio real en esta fase. En un entorno de producción, la refactorización en módulos independientes por capa sería el paso natural siguiente.

Herramientas de cálculo. Cada agente dispone de una función que extrae los datos de su dominio y los devuelve como cadena de texto compacta para el prompt. Existen versiones en tiempo real y versiones históricas para el backtesting:

- `herramienta_tecnica()` y `herramienta_tecnica_historica()`: calculan RSI, MACD, Bollinger y medias móviles. La versión histórica filtra los datos hasta la fecha indicada para evitar *look-ahead bias*.
- `herramienta_fundamental()`: obtiene ratios financieros de Yahoo Finance en tiempo real. No tiene versión histórica porque yfinance no proporciona series temporales de fundamentales de forma gratuita.
- `herramienta_riesgo()`: calcula volatilidad, Sharpe, VaR, drawdown máximo, beta y alpha sobre los datos de precio.
- `herramienta_sentimiento_historico()`: recupera titulares del dataset FNSPID para la fecha indicada. Incluye la alternativa a proxy de precio para META, HON y fechas posteriores al 9 de enero de 2024.
- `herramienta_montecarlo()` y `herramienta_montecarlo_historica()`: ejecutan la simulación Monte Carlo. La versión histórica usa únicamente datos anteriores a la fecha de la señal.

Agentes especializados. Las funciones `agente_tecnico()`, `agente_fundamental()`, `agente_riesgo()`, `agente_sentimiento()` y `agente_montecarlo()` invocan su herramienta correspondiente, construyen el prompt y llaman a Mistral mediante

`llm.with_structured_output(SenalInversion)`. Todas aceptan un parámetro opcional `fecha` que activa el modo histórico.

Orquestación. La función `orquestador()` invoca los cinco agentes secuencialmente y construye el prompt final con sus señales. Devuelve un objeto `DecisionFinal`. Para el backtesting, `generar_senales_mensuales()` recorre mes a mes el periodo 2019–2024, llama al orquestador para cada acción y guarda las señales en CSV con un punto de control por mes para permitir la reanudación en caso de interrupción.

Cabe mencionar una limitación en el agente fundamental: la función `herramienta_fundamental()` obtiene los ratios financieros de Yahoo Finance en tiempo real, por lo que siempre devuelve los valores actuales independientemente de la fecha de la señal. Esto introduce un *look-ahead bias* potencial en el modo histórico, ya que el sistema vería ratios de 2024–2025 al generar señales de 2019.

En la práctica este sesgo no afecta a los resultados del backtesting del sistema LLM puro, dado que `generar_senales_mensuales()` utiliza únicamente indicadores técnicos calculados con `calcular_indicadores_mes()` y no invoca al agente fundamental. El sistema híbrido resuelve este problema completamente: el RF fundamental usa retornos de precio a 60, 120 y 252 días, que sí están disponibles en cualquier fecha histórica.

6.2. Implementación del sistema híbrido

El sistema híbrido se implementa en un único módulo Python, `sistema_hibrido.py`, que concentra las clases de los tres Random Forest especializados, el agente de sentimiento FinBERT, la función de simulación Monte Carlo y el orquestador. Al igual que en el sistema LLM puro, esta decisión responde al carácter de prototipo de investigación del trabajo, donde mantener toda la lógica accesible desde un único punto de importación facilita la experimentación iterativa y la reproducibilidad de los resultados.

`_construir_features_ticker()`. Función de nivel de módulo que recibe el DataFrame de precios de un ticker y calcula todas las características necesarias para los tres RF: indicadores técnicos, de riesgo y de largo plazo. Devuelve un DataFrame con una fila por día. Al filtrar los datos hasta una fecha concreta antes de llamarla, se garantiza que no hay *look-ahead bias*.

Clase `AgenteSentimientoFinBERT`. Encapsula toda la lógica de FinBERT. El modelo se carga con *lazy loading* la primera vez que se necesita, no al importar el módulo. El método `_score_titulares()` procesa los titulares en batch en una sola llamada al pipeline. El método público `señal()` acepta un parámetro `fecha` para el modo histórico, en cuyo caso recupera los titulares de FNSPID mediante `_obtener_titulares_historicos()`.

Clase `AgenteRF`. Implementa un Random Forest genérico especializable por dominio. Recibe en el constructor el nombre del agente y la lista de características. El método `entrenar()` realiza la búsqueda de hiperparámetros con `GridSearchCV` y `TimeSeriesSplit`, guarda el modelo en disco con `joblib` y lo carga automáticamente si ya existe. El método `señal()` recibe un diccionario de características y devuelve un objeto `SenalAgente` con la decisión y la probabilidad máxima convertida en confianza.

Cabe destacar que la beta de cada ticker se inicializa a 1,0 por defecto en `_construir_features_ticker()`. Solo se sobreescribe con el valor real calculado frente a SPY cuando se llama desde `construir_dataset()` durante el entrenamiento, donde los retornos de SPY se descargan una única vez y se pasan como parámetro. En inferencia individual la beta permanece en 1,0.

Función `_senal_montecarlo()`. Función independiente que ejecuta la simulación Monte Carlo. Usa una semilla fija (`seed=42`) para garantizar la reproducibilidad de los resultados.

Clase `AgentesV3`. Clase contenedora del sistema completo. Instancia los tres `AgenteRF`, el `AgenteSentimientoFinBERT` y gestiona la conexión con Mistral. El método `entrenar()` construye el dataset completo de características mediante `construir_dataset()`, descarga SPY para el cálculo de beta y entrena los tres RF secuencialmente. El método `orquestador()` extrae las características actuales con `_features_actuales()`, obtiene las cinco señales y llama a Mistral con el prompt compacto. El método `generar_senales_mensuales()` reproduce el mismo flujo mes a mes sobre el periodo histórico con un punto de control automático.

6.3. Entrenamiento de los Random Forest especializados

El entrenamiento de los tres RF se gestiona desde el método `entrenar()` de la clase `AgentesV3`. El proceso sigue los pasos que se describen a continuación.

En primer lugar, si los tres archivos PKL ya existen en `results/modelos_v3/` y el parámetro `forzar` es `False`, los modelos se cargan desde disco sin reentrenar. Esto evita repetir un proceso costoso entre sesiones de trabajo.

Si no existen, se construye el conjunto de datos. Los archivos `TICKER_train.parquet` del periodo 2010–2018 se concatenan con los datos 2019–2024. Si los archivos de entrenamiento no están disponibles, se usa únicamente el periodo 2019–2024 con un aviso por pantalla. Paralelamente se descarga el historial de SPY para calcular la beta de cada ticker; si la descarga falla, la beta queda en 1,0. A continuación se llama a `construir_dataset()`, que itera sobre los 50 tickers, calcula las características con `_construir_features_ticker()` y asigna la etiqueta: BUY si el retorno a 20 días supera el 5 %, SELL si cae más del 5 %, y HOLD en caso contrario. El dataset resultante se guarda en parquet para no recalcularlo en futuras ejecuciones.

Por último, los tres RF se entrenan secuencialmente. Cada uno usa `GridSearchCV` con `TimeSeriesSplit` de 5 particiones y optimiza `f1_macro` sobre su subconjunto de características. La semilla aleatoria es 42 en todos los casos para garantizar reproducibilidad. Una vez entrenado cada modelo, se serializa con `joblib` en su PKL correspondiente. El método devuelve un diccionario con las métricas de cada RF: precisión en entrenamiento y test, mejores hiperparámetros encontrados y el informe de clasificación completo.

6.4. Integración de FinBERT con FNSPID

La integración del análisis de sentimiento se implementa en la clase `AgenteSentimientoFinBERT` de `sistema_hibrido.py`.

El dataset FNSPID se carga una única vez en memoria al inicio mediante una función de caché global, evitando lecturas repetidas del archivo parquet en cada llamada. El modelo FinBERT se carga con *lazy loading*: el pipeline de HuggingFace se inicializa la primera vez que se necesita, no al importar el módulo, lo que reduce el tiempo de arranque y libera la GPU para Mistral al ejecutarse en CPU (`device=-1`).

Para obtener titulares históricos, el método `_obtener_titulares_historicos()` busca en FNSPID las noticias del ticker en una ventana de 7 días anteriores a la fecha de la

señal. Si esa ventana está vacía, la amplia a 30 días. En ambos casos devuelve un máximo de 5 titulares. Dos casos devuelven lista vacía directamente: los tickers sin cobertura en FNSPID (META y HON) y las fechas posteriores al 9 de enero de 2024, que es el último día con datos en el dataset.

El método `_score_titulares()` procesa la lista de titulares en una única llamada al pipeline en batch. Cada titular se trunca a 512 caracteres antes de enviarse. FinBERT clasifica cada titular como *positive*, *negative* o *neutral* con una probabilidad asociada. La puntuación neta se calcula sumando las probabilidades positivas y restando las negativas, dividiendo entre el número de titulares:

$$score = \frac{1}{n} \sum_{i=1}^{n} \begin{cases} +p_i & \text{si positivo} \\ -p_i & \text{si negativo} \\ 0 & \text{si neutro} \end{cases} \tag{6.1}$$

Cuando la lista de titulares está vacía, la puntuación es 0,0 y la señal resultante es HOLD con confianza baja. Esto aplica tanto a META y HON como a cualquier fecha posterior al corte del dataset. Los umbrales de clasificación son +0,15 para BUY y −0,15 para SELL.

6.5. Sistema de backtesting

6.5.1. Función `backtesting()`

La función `backtesting()` simula la evolución de una cartera día a día durante el periodo 2019–2024 a partir de un DataFrame de señales mensuales y los precios de cierre diarios de las 50 acciones. El capital inicial es de 100.000$.

El bucle principal recorre cada día de mercado del periodo. Para cada día se ejecutan dos operaciones en orden:

Primero, se revisan las posiciones abiertas. Cualquier ticker con señal distinta de BUY se liquida al precio de cierre del día, aplicando una comisión del 0,1 % sobre el importe de la venta. Esto incluye las señales HOLD, que por tanto tienen el mismo efecto que SELL. La decisión de tratar HOLD como liquidación fuerza al sistema a justificar activamente cada posición mes a mes, evitando acumular rentabilidades por inercia.

Segundo, se procesan las señales BUY. Para cada ticker con señal BUY que no esté ya en cartera, se calcula el capital disponible por posición dividiendo el capital libre entre los slots disponibles. Se compra el máximo número entero de acciones que cabe en ese importe, aplicando una comisión del 0,1 % sobre la compra. Si el número de señales BUY supera el máximo de posiciones del perfil, solo se procesan las primeras hasta el límite. Al final de cada día se registra el valor total de la cartera sumando el capital en efectivo y el valor de mercado de las posiciones abiertas.

6.5.2. Generación de señales mensuales

Cada arquitectura tiene su propia función de generación de señales: `generar_senales_mensuales()` para el sistema LLM puro y `generar_senales_mensuales()` de `AgentesV3` para el sistema híbrido. Ambas siguen el mismo patrón: recorren mes a mes el periodo 2019–2024, generan las señales para las 50 acciones y las guardan en CSV con un punto de control

automático por mes. Si el proceso se interrumpe, la siguiente ejecución carga el CSV existente y retoma desde el último mes procesado.

En el sistema LLM puro las señales se guardan en `results/señales_mensuales_{perfil}.csv` y en el híbrido en `results/v3_señales_mensuales_{perfil}.csv`. El backtesting de la v3 filtra además los tickers que no estén en la lista oficial antes de simular, descartando posibles alucinaciones del LLM en el campo ticker.

6.5.3. Cálculo de métricas

La función `calcular_metricas()` recibe el historial de valor diario de la cartera y calcula las métricas descritas en la sección 3.4: retorno total, CAGR, ratio de Sharpe, ratio de Sortino, alpha, beta, drawdown máximo e Information Ratio. La tasa libre de riesgo se fija en 0 para el cálculo del ratio de Sharpe y Sortino, y en el 5 % anual para el cálculo del alpha, como aproximación convencional al rendimiento del bono del Tesoro estadounidense.

Capítulo 7

Evaluación y resultados

7.1. Metodología del backtesting

El backtesting se realiza sobre el periodo 2019–2024, con un capital inicial de 100.000$ para todas las estrategias. Se evalúan cuatro estrategias con tres perfiles de riesgo cada una, lo que da un total de doce configuraciones comparadas entre sí y frente a dos referencias de compra y mantenimiento: el ETF SPY, que replica el índice S&P 500, y una cartera equiponderada de las 50 acciones seleccionadas.

Las cuatro estrategias evaluadas son:

- **Señales cuantitativas**: sistema de referencia basado en umbrales fijos de RSI y MACD sin intervención de ningún modelo de aprendizaje automático.
- **Random Forest monolítico**: un único RF entrenado sobre indicadores técnicos, sin separación por dominio ni orquestador LLM.
- **Sistema LLM puro**: Mistral 7B con señales basadas en indicadores técnicos calculados mensualmente para las 50 acciones.
- **Sistema híbrido**: tres RF especializados, FinBERT y simulación Monte Carlo, orquestados por Mistral 7B.

Las métricas calculadas para cada configuración son el retorno total, el CAGR, la volatilidad anualizada, el ratio de Sharpe, el ratio de Sortino, el alpha, la beta, el drawdown máximo y el Information Ratio. La tasa libre de riesgo se fija en 0 para el cálculo del ratio de Sharpe y Sortino, y en el 5 % anual para el cálculo del alpha, como aproximación convencional al rendimiento del bono del Tesoro estadounidense. El benchmark de referencia es el ETF SPY, cuyo historial se descarga con `yfinance` al inicio del notebook.

7.2. Señales cuantitativas

El sistema de señales cuantitativas actúa como estrategia de referencia. No emplea ningún modelo de aprendizaje automático ni LLM; las decisiones se toman únicamente con umbrales fijos de RSI y MACD. Cada perfil combina estas señales de forma distinta: el conservador exige que RSI y MACD coincidan en la misma dirección, el moderado usa únicamente la señal MACD, y el agresivo actúa cuando cualquiera de los dos indicadores da señal. Los resultados se recogen en la tabla 7.1.

Tabla 7.1: Métricas del sistema cuantitativo (2019–2024)

Perfil	Retorno	CAGR	Vol.	Sharpe	Sortino	MaxDD	Beta	Alpha	IR
Conservador	−0,32 %	−0,05 %	4,07 %	0,007	0,005	−10,11 %	0,053	−5,65 %	−0,928
Moderado	+241,12 %	+22,74 %	17,27 %	1,274	1,849	−28,50 %	0,610	+9,17 %	0,286
Agresivo	+41,52 %	+5,97 %	14,37 %	0,476	0,632	−31,00 %	0,493	−4,50 %	−0,757
Buy&Hold SPY	+158,40 %	+17,18 %	19,84 %	0,899	1,088	−33,72 %	1,000	0,00 %	0,000
Buy&Hold 50 acc	+170,25 %	+18,06 %	20,72 %	0,906	1,081	−37,89 %	1,020	+0,68 %	0,208

El perfil moderado es el único que supera al Buy&Hold SPY tanto en retorno (+241,12 % frente a +158,40 %) como en ratio de Sharpe (1,274 frente a 0,899), con un alpha positivo del 9,17 %. Su beta de 0,610 indica una exposición al mercado moderada; consigue mayor rentabilidad que el índice asumiendo menos riesgo sistemático, aunque con un drawdown máximo del −28,50 % que refleja la exposición durante las caídas de 2020 y 2022. El éxito del MACD como único criterio en este periodo se debe probablemente a que el mercado estuvo mayoritariamente en tendencia alcista entre 2019 y 2024, contexto en el que el MACD funciona bien al seguir tendencias.

El perfil conservador, al exigir la coincidencia de RSI y MACD, opera muy poco, su beta de apenas 0,053 confirma que prácticamente no tiene exposición al mercado, y obtiene un retorno prácticamente nulo (−0,32 %) con un alpha negativo del −5,65 %.

El perfil agresivo genera demasiadas señales al actuar con cualquier indicador y termina muy por debajo del benchmark (+41,52 %), con un alpha negativo del −4,50 % a pesar de tener una beta razonable de 0,493.

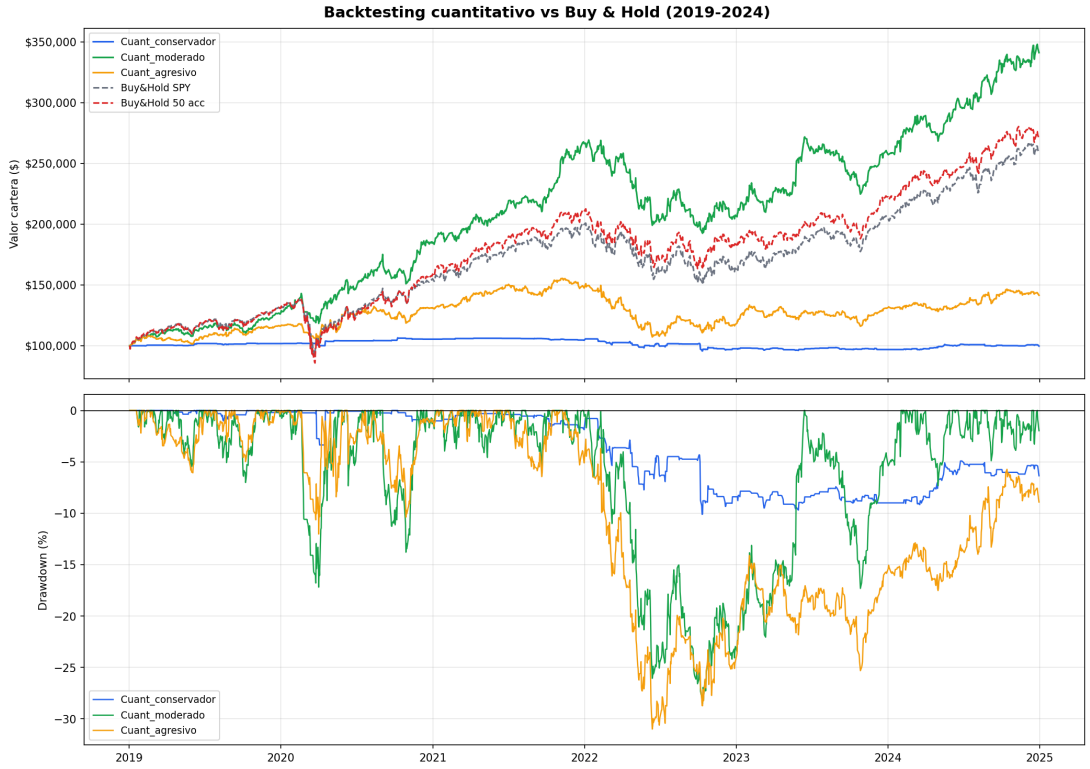


Figura 7.1: Evolución del valor de cartera y drawdown para el sistema cuantitativo frente a Buy&Hold SPY (2019–2024).

7.3. Random Forest monolítico

El Random Forest monolítico es un único modelo entrenado con `GridSearchCV` sobre los indicadores técnicos de las 50 acciones, sin separación por dominio ni orquestador LLM. Los tres perfiles de riesgo aplican los mismos umbrales de confianza y límites de posiciones descritos en la sección 5.4. Los resultados se recogen en la tabla 7.2.

Tabla 7.2: Métricas del Random Forest monolítico (2019–2024)

Perfil	Retorno	CAGR	Vol.	Sharpe	Sortino	MaxDD	Beta	Alpha	IR
Conservador	+105,17 %	+12,75 %	18,01 %	0,757	0,855	−23,26 %	0,676	−0,05 %	−0,309
Moderado	+64,13 %	+8,63 %	13,58 %	0,678	0,709	−22,58 %	0,493	−2,12 %	−0,627
Agresivo	+31,88 %	+4,73 %	10,96 %	0,478	0,440	−24,28 %	0,384	−4,69 %	−0,866
Buy&Hold SPY	+158,40 %	+17,18 %	19,84 %	0,899	1,088	−33,72 %	1,000	0,00 %	0,000
Buy&Hold 50 acc	+170,25 %	+18,06 %	20,72 %	0,906	1,081	−37,89 %	1,020	+0,68 %	0,208

Ninguno de los tres perfiles supera al benchmark. El conservador obtiene el mejor retorno (+105,17 %, Sharpe 0,757) pero queda lejos del Buy&Hold SPY (+158,40 %, Sharpe 0,899). Su alpha es prácticamente nulo (−0,05 %), lo que indica que el modelo no genera valor respecto al mercado una vez ajustado por riesgo.

Un resultado llamativo es que a mayor agresividad del perfil, menor retorno: el agresivo obtiene solo +31,88 % frente al +105,17 % del conservador. Esto se explica porque el RF genera muchas señales de baja confianza al estar entrenado con un dataset donde HOLD es la clase dominante. El perfil conservador filtra estas señales y opera únicamente con las más sólidas; el agresivo acepta todas, incluyendo las erróneas, lo que deteriora el resultado final.

La figura 7.2 muestra la importancia de variables y la matriz de confusión: la volatilidad y las medias móviles son las variables más determinantes, y el modelo tiende a predecir HOLD en la mayoría de casos con poca capacidad para discriminar BUY y SELL.

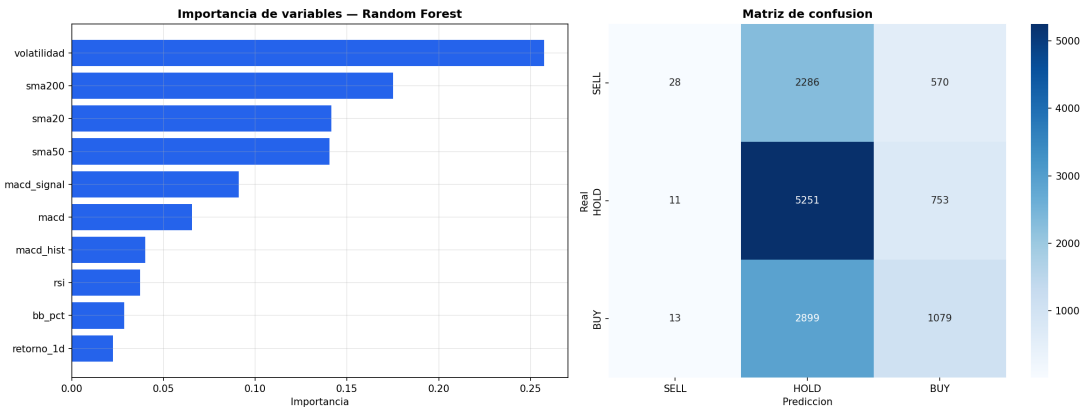


Figura 7.2: Importancia de variables y matriz de confusión del Random Forest monolítico.

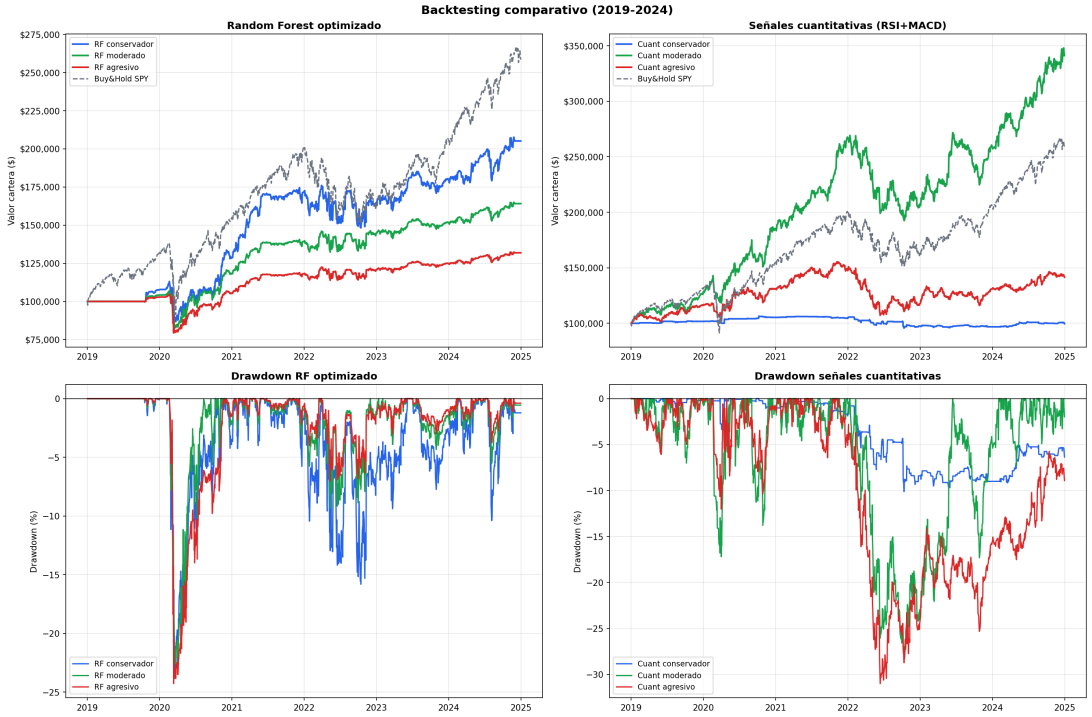


Figura 7.3: Evolución del valor de cartera y drawdown para el RF monolítico y el sistema cuantitativo frente a Buy&Hold SPY (2019–2024).

7.4. Sistema LLM puro

El sistema LLM puro emplea Mistral 7B con señales basadas en indicadores técnicos calculados mensualmente. Los resultados se recogen en la tabla 7.3.

Tabla 7.3: Métricas del sistema LLM puro (2019–2024)

Perfil	Retorno	CAGR	Vol.	Sharpe	Sortino	MaxDD	Beta	Alpha	IR
Conservador	+75,45 %	+9,84 %	5,75 %	1,663	2,160	−4,98 %	0,120	+3,03 %	−0,454
Moderado	+116,41 %	+13,76 %	8,71 %	1,525	1,578	−17,10 %	0,334	+4,00 %	−0,317
Agresivo	+101,19 %	+12,38 %	8,45 %	1,425	1,654	−16,00 %	0,364	+2,36 %	−0,435
Buy&Hold SPY	+158,40 %	+17,18 %	19,84 %	0,899	1,088	−33,72 %	1,000	0,00 %	0,000
Buy&Hold 50 acc	+170,25 %	+18,06 %	20,72 %	0,906	1,081	−37,89 %	1,020	+0,68 %	0,208

El rasgo más destacable del sistema LLM puro es su excepcional control del riesgo. Los tres perfiles presentan volatilidades muy bajas (entre el 5,75 % y el 8,71 %) frente al 19,84 % del SPY, y drawdowns máximos muy contenidos (entre −4,98 % y −17,10 %) frente al −33,72 % del benchmark. Esto se traduce en ratios de Sharpe superiores a 1,4 en los tres perfiles, muy por encima del 0,899 del SPY.

El motivo de esta baja exposición al mercado es la beta reducida de todos los perfiles (entre 0,120 y 0,364), lo que indica que Mistral tiende a emitir señales conservadoras y permanece fuera del mercado una parte importante del tiempo. Esto explica también por qué el retorno absoluto queda por debajo del Buy&Hold SPY en los tres casos: el sistema no pierde mucho, pero tampoco captura la totalidad de las subidas del mercado.

El alpha es positivo en los tres perfiles (+3,03 %, +4,00 % y +2,36 %), lo que confirma que las señales generadas añaden valor real por encima de lo esperado dado el riesgo

asumido. El IR negativo indica sin embargo que la estrategia no bate al benchmark de forma consistente en términos de error de seguimiento, lo que es coherente con la baja exposición al mercado.

La figura 7.4 muestra cómo los tres perfiles del sistema LLM puro crecen de forma gradual y estable a lo largo del periodo, sin las caídas bruscas del benchmark en 2020 y 2022, lo que refleja la tendencia del sistema a mantenerse fuera del mercado en periodos de incertidumbre.

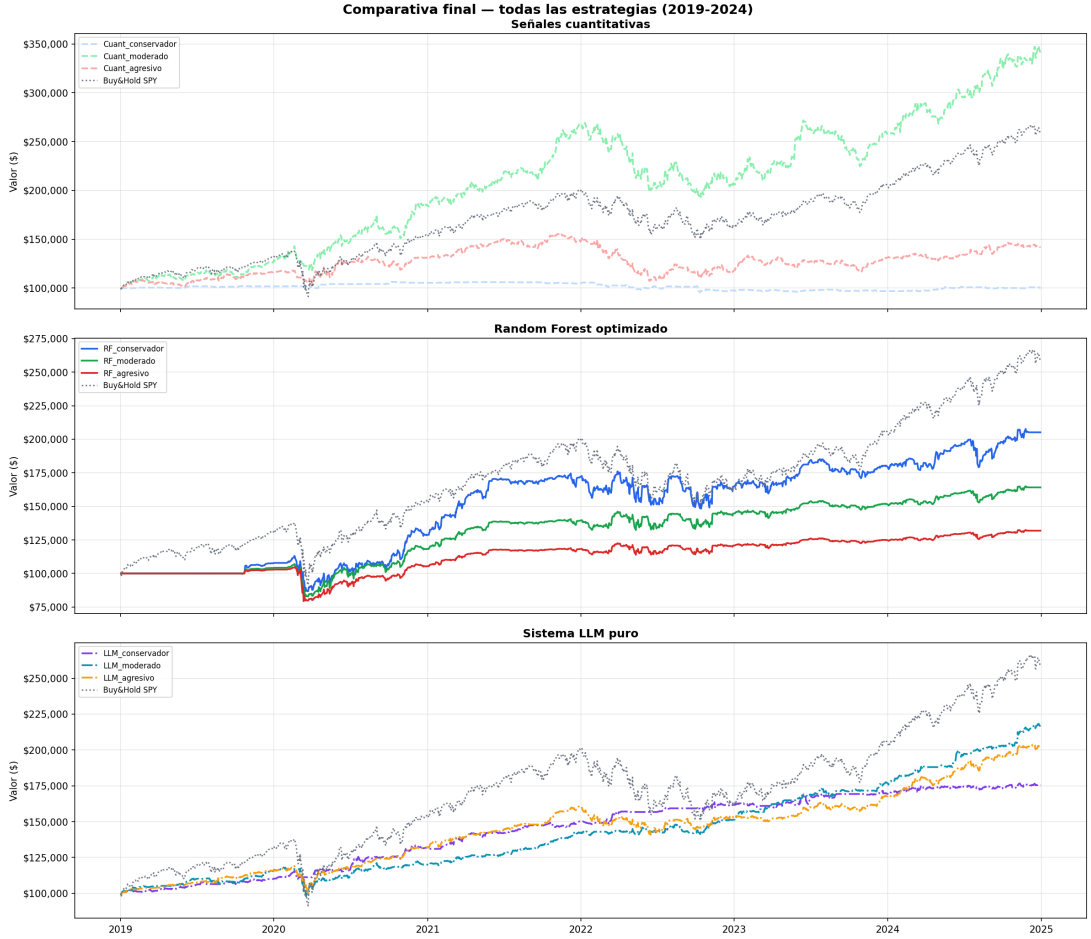


Figura 7.4: Evolución del valor de cartera del sistema LLM puro frente a Buy&Hold SPY (2019–2024). Panel inferior.

7.5. Sistema híbrido

El sistema híbrido combina tres RF especializados, FinBERT y simulación Monte Carlo orquestados por Mistral 7B. A diferencia del sistema LLM puro, dispone de datos de sentimiento real y de indicadores de riesgo y fundamentales, lo que le permite tomar decisiones más informadas. Los resultados se recogen en la tabla 7.4.

El sistema híbrido es la arquitectura con mejores resultados absolutos del trabajo. El perfil agresivo alcanza un retorno del +334,23 % con un CAGR del 27,79 %, superando ampliamente al Buy&Hold SPY (+158,40 %) y al Buy&Hold 50 acciones (+170,25 %). Es además el único perfil de todo el estudio con un IR positivo (0,690), lo que indica

Tabla 7.4: Métricas del sistema híbrido (2019–2024)

Perfil	Retorno	CAGR	Vol.	Sharpe	Sortino	MaxDD	Beta	Alpha	IR
Conservador	+16,02 %	+2,51 %	5,56 %	0,474	0,318	−8,32 %	0,137	−4,13 %	−0,855
Moderado	+120,09 %	+14,08 %	14,94 %	0,957	1,251	−21,33 %	0,650	+0,95 %	−0,346
Agresivo	+334,23 %	+27,79 %	21,35 %	1,256	1,761	−31,18 %	0,864	+10,73 %	0,690
Buy&Hold SPY	+158,40 %	+17,18 %	19,84 %	0,899	1,088	−33,72 %	1,000	0,00 %	0,000
Buy&Hold 50 acc	+170,25 %	+18,06 %	20,72 %	0,906	1,081	−37,89 %	1,020	+0,68 %	0,208

que no solo genera mayor rentabilidad sino que lo hace de forma consistente respecto al benchmark.

El alpha del perfil agresivo (+10,73 %) es el más alto de todas las estrategias evaluadas, lo que confirma que el sistema añade valor real más allá de la simple exposición al mercado. Su beta de 0,864 indica una exposición elevada pero inferior al mercado, y su drawdown máximo de −31,18 % es comparable al del SPY (−33,72 %), lo que supone asumir un riesgo similar a cambio de un retorno muy superior.

El perfil moderado obtiene un retorno del +120,09 % con un Sharpe de 0,957, superando al Buy&Hold SPY en retorno pero con menor Sharpe. Su alpha positivo (+0,95 %) indica que también genera valor, aunque de forma más moderada.

El perfil conservador es el único con alpha negativo (−4,13 %) y un retorno muy bajo (+16,02 %). Su beta de apenas 0,137 indica que permanece casi siempre fuera del mercado, lo que explica tanto la baja rentabilidad como el drawdown máximo muy contenido (−8,32 %). El umbral de confianza de 7/10 resulta demasiado restrictivo para este sistema, que genera muchas señales de confianza media que el perfil conservador descarta.

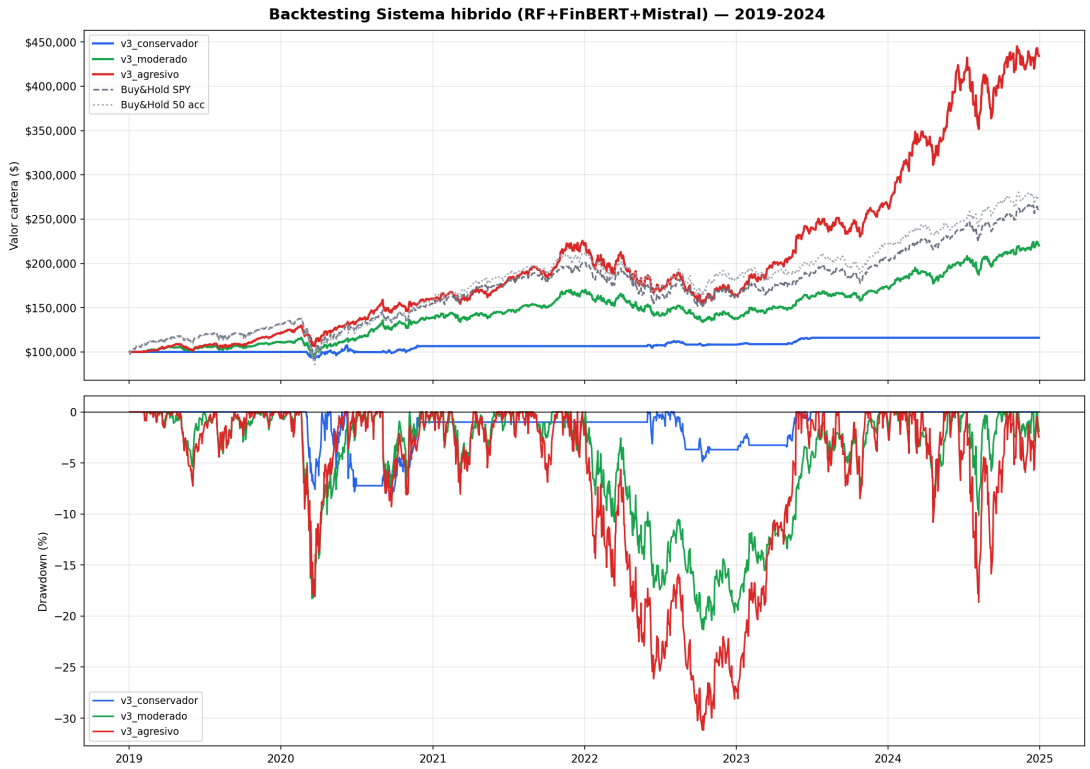


Figura 7.5: Evolución del valor de cartera del sistema híbrido frente a Buy&Hold SPY (2019–2024).

7.6. Comparativa final

La tabla 7.5 recoge las métricas de todas las estrategias evaluadas, permitiendo una comparación directa entre sistemas.

Tabla 7.5: Comparativa final de todas las estrategias (2019–2024)

Estrategia	Retorno	CAGR	Vol.	Sharpe	Sortino	MaxDD	Beta	Alpha	IR
Cuant conservador	−0,32 %	−0,05 %	4,07 %	0,007	0,005	−10,11 %	0,053	−5,65 %	−0,928
Cuant moderado	+241,12 %	+22,74 %	17,27 %	1,274	1,849	−28,50 %	0,610	+9,17 %	0,286
Cuant agresivo	+41,52 %	+5,97 %	14,37 %	0,476	0,632	−31,00 %	0,493	−4,50 %	−0,757
RF conservador	+105,17 %	+12,75 %	18,01 %	0,757	0,855	−23,26 %	0,676	−0,05 %	−0,309
RF moderado	+64,13 %	+8,63 %	13,58 %	0,678	0,709	−22,58 %	0,493	−2,12 %	−0,627
RF agresivo	+31,88 %	+4,73 %	10,96 %	0,478	0,440	−24,28 %	0,384	−4,69 %	−0,866
LLM conservador	+75,45 %	+9,84 %	5,75 %	1,663	2,160	−4,98 %	0,120	+3,03 %	−0,454
LLM moderado	+116,41 %	+13,76 %	8,71 %	1,525	1,578	−17,10 %	0,334	+4,00 %	−0,317
LLM agresivo	+101,19 %	+12,38 %	8,45 %	1,425	1,654	−16,00 %	0,364	+2,36 %	−0,435
Híbrido conservador	+16,02 %	+2,51 %	5,56 %	0,474	0,318	−8,32 %	0,137	−4,13 %	−0,855
Híbrido moderado	+120,09 %	+14,08 %	14,94 %	0,957	1,251	−21,33 %	0,650	+0,95 %	−0,346
Híbrido agresivo	+334,23 %	+27,79 %	21,35 %	1,256	1,761	−31,18 %	0,864	+10,73 %	0,690
Buy&Hold SPY	+158,40 %	+17,18 %	19,84 %	0,899	1,088	−33,72 %	1,000	0,00 %	0,000
Buy&Hold 50 acc	+170,25 %	+18,06 %	20,72 %	0,906	1,081	−37,89 %	1,020	+0,68 %	0,208

Analizando los resultados de forma conjunta se pueden extraer varias conclusiones. En términos de retorno absoluto, el sistema híbrido agresivo es el claro ganador con +334,23 %, seguido del cuantitativo moderado con +241,12 %. Sin embargo el retorno absoluto no es la única métrica relevante.

En términos de eficiencia del riesgo, el sistema LLM puro destaca por sus ratios de Sharpe superiores a 1,4 en los tres perfiles, con volatilidades muy bajas (entre 5,75 % y 8,71 %) y drawdowns máximos contenidos. Es el sistema más adecuado para un inversor que prioriza la estabilidad sobre el retorno absoluto.

El único sistema con IR positivo es el híbrido agresivo (IR=0,690), lo que lo convierte en el único que bate al benchmark de forma consistente en términos de error de seguimiento. También tiene el alpha más alto de todas las estrategias (+10,73 %), solo superado por el cuantitativo moderado (+9,17 %).

El RF monolítico es el sistema con peores resultados generales: ninguno de sus tres perfiles supera al benchmark y todos presentan alpha negativo o nulo. El cuantitativo moderado es sorprendentemente competitivo gracias a la simple señal MACD, lo que sugiere que en un mercado alcista sostenido como el de 2019–2024 las estrategias de seguimiento de tendencia funcionan bien.

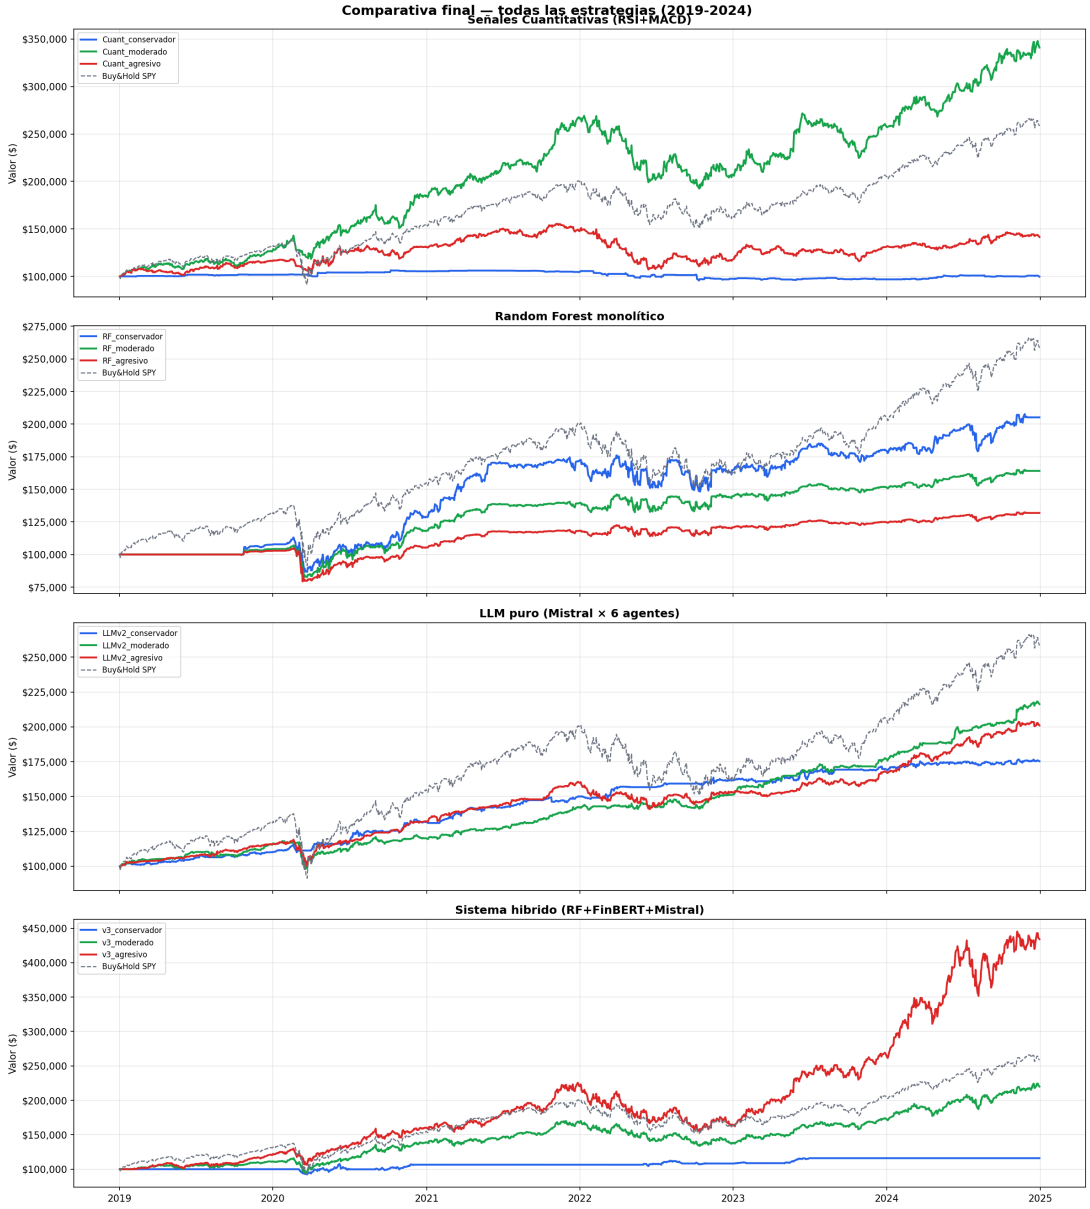


Figura 7.6: Comparativa de la evolución de cartera para todas las estrategias evaluadas (2019–2024).

Capítulo 8

Conclusiones y trabajo futuro

8.1. Conclusiones

Este trabajo ha diseñado, implementado y evaluado un sistema multiagente de inversión sobre un subconjunto de 50 acciones del S&P 500, con dos arquitecturas distintas basadas en LLM y aprendizaje automático. A continuación se recogen las conclusiones respecto a cada uno de los objetivos planteados.

Objetivo 1: diseño e implementación de dos arquitecturas. Se han implementado satisfactoriamente el sistema LLM puro y el sistema híbrido. La principal diferencia entre ambos es el coste computacional: el sistema LLM puro requiere seis llamadas a Mistral por acción en tiempo real, mientras que el híbrido reduce esto a una sola llamada al reservar el LLM únicamente para la orquestación final. Esto hizo viable el backtesting completo con todos los agentes en el sistema híbrido, algo imposible en el LLM puro a escala de 72 meses y 50 acciones.

Objetivo 2: integración de FinBERT y FNSPID. El agente de sentimiento basado en FinBERT y el dataset FNSPID se ha integrado correctamente en el sistema híbrido. La cobertura del dataset es amplia (48 de 50 tickers) y el procesamiento en batch sobre CPU permite ejecutarlo en paralelo con Mistral en GPU sin interferencias. La contribución del sentimiento a las señales finales es difícil de aislar, pero el perfil agresivo del sistema híbrido, que es el que más señales BUY acepta, obtiene el mejor resultado global, lo que sugiere que las señales de sentimiento aportan información complementaria a los indicadores técnicos y de riesgo.

Objetivo 3: sistema de perfiles de riesgo. Los tres perfiles funcionan de forma diferenciada en todos los sistemas evaluados. El perfil conservador tiende a operar poco y preservar capital; el agresivo maximiza la exposición al mercado con mayor riesgo. Un hallazgo inesperado es que en el RF monolítico el perfil conservador supera al agresivo en retorno, lo que revela una limitación del modelo para generar señales de alta confianza.

Objetivo 4: validación mediante backtesting histórico. Ambas arquitecturas han sido validadas sobre el periodo 2019–2024 con métricas financieras estándar. El sistema híbrido agresivo obtiene el mejor resultado global (+334,23 %, CAGR +27,79 %, alpha +10,73 %) y es el único con IR positivo (0,690), lo que indica que bate al benchmark de forma consistente. El sistema LLM puro destaca por su control del riesgo, con ratios de Sharpe superiores a 1,4 en los tres perfiles y drawdowns muy contenidos.

Objetivo 5: comparativa frente a estrategias de referencia. Frente al Buy&Hold SPY (+158,40 %), dos estrategias lo superan en retorno absoluto: el cuantitativo moderado (+241,12 %) y el híbrido agresivo (+334,23 %). En términos de rentabilidad ajustada por

riesgo, el sistema LLM puro es el más eficiente con diferencia. El RF monolítico es el sistema menos competitivo, lo que sugiere que un único modelo sin especialización por dominio ni orquestador LLM no es suficiente para superar al mercado.

Como conclusión general, los resultados demuestran que la combinación de modelos especializados con un orquestador LLM añade valor real respecto a las estrategias de referencia, especialmente en el perfil agresivo del sistema híbrido. Sin embargo, los resultados también muestran que el periodo 2019–2024 fue especialmente favorable para estrategias de seguimiento de tendencia por el carácter alcista del mercado tecnológico, lo que invita a ser cauto al generalizar estas conclusiones a otros periodos o condiciones de mercado.

Un resultado que merece reflexión es el rendimiento del sistema cuantitativo moderado. Una estrategia tan simple como seguir la señal MACD con umbrales fijos consigue +241,12 % y un alpha del +9,17 %, superando en retorno absoluto al sistema LLM puro y quedando cerca del híbrido moderado. Esto pone de manifiesto que, en condiciones de mercado tendencial, los modelos matemáticos clásicos son difíciles de superar y que el valor añadido por los LLM no es automático. Mistral 7B, operando solo sobre indicadores técnicos en el backtesting del sistema LLM puro, no supera al MACD en retorno absoluto a pesar de su mayor sofisticación.

Donde sí parece añadir valor el enfoque multiagente es en la combinación de dominios: el sistema híbrido, al integrar análisis técnico, de riesgo, de sentimiento y simulación estocástica, consigue el único IR positivo del estudio y el alpha más alto. Esto sugiere que el análisis de sentimiento financiero sí aporta información complementaria cuando se combina con otros dominios, pero que por sí solo o con LLMs operando sobre datos técnicos simples, el valor añadido es limitado frente a estrategias cuantitativas bien calibradas.

8.2. Trabajo futuro

Los resultados obtenidos abren varias líneas de mejora y extensión del sistema que se describen a continuación.

Datos fundamentales históricos. La principal limitación del agente fundamental es el uso de retornos de precio a largo plazo como aproximación a la salud empresarial. Una mejora directa sería incorporar series temporales de ratios financieros reales mediante APIs de pago como Compustat o Intrinio, lo que permitiría entrenar el RF fundamental con datos verdaderamente representativos de la situación de cada empresa en cada momento.

Optimización de cartera. El sistema actual distribuye el capital de forma equitativa entre las posiciones activas. Una mejora natural sería aplicar optimización de cartera mediante el modelo de Markowitz, ponderando cada posición según su relación riesgo-rentabilidad esperada y la correlación entre activos.

Mayor frecuencia de señales. El sistema opera con rebalanceo mensual. Reducir la frecuencia a semanal o quincenal permitiría reaccionar más rápidamente a cambios en el mercado, aunque aumentaría el coste computacional y las comisiones.

Modelos LLM más potentes. Mistral 7B fue elegido por su viabilidad en hardware local. Probar modelos de mayor capacidad como Llama 3.1 70B o modelos propietarios vía API podría mejorar la calidad de las decisiones del orquestador, especialmente en situaciones de señales contradictorias entre agentes.

Fine-tuning de FinBERT. El modelo FinBERT utilizado es genérico. Realizar un fine-tuning específico sobre el dataset FNSPID con etiquetas de impacto real en precio podría mejorar la precisión del agente de sentimiento.

Validación en otros periodos y mercados. El backtesting cubre un periodo mayoritariamente alcista. Validar el sistema en periodos de mercado bajista prolongado o en mercados distintos al estadounidense permitiría evaluar su robustez en condiciones adversas.

Sistema autónomo de operación en tiempo real. Una evolución natural del sistema sería dotarlo de capacidad de operación autónoma en bolsa: conectarlo a un broker mediante su API para ejecutar órdenes de compra y venta directamente, sin intervención humana. En este escenario el sistema leería en tiempo real los precios del mercado, noticias de medios financieros tradicionales y contenido de redes sociales como Twitter/X, Reddit o Stocktwits, donde la actividad de la comunidad inversora tiene un impacto demostrado en determinados activos. El orquestador integraría todas estas fuentes para tomar decisiones de forma continua y ejecutarlas automáticamente, constituyendo un gestor de cartera autónomo completo.

Desarrollo de modelos propios. Una línea de investigación a largo plazo sería sustituir los modelos de terceros por modelos desarrollados en propiedad: un modelo de lenguaje financiero entrenado desde cero sobre corpus especializados, un modelo de sentimiento financiero propio en lugar de FinBERT, y modelos predictivos específicos para cada dominio de análisis. Esto eliminaría la dependencia de herramientas externas, permitiría un control total sobre el comportamiento del sistema y abriría la puerta a su comercialización o transferencia tecnológica.

Bibliografía

[1] M. López de Prado, *Advances in Financial Machine Learning*. Wiley, 2018.

[2] A. Vaswani et al., "Attention Is All You Need," en *Advances in Neural Information Processing Systems*, vol. 30, 2017.

[3] D. Araci, "FinBERT: Financial Sentiment Analysis with Pre-trained Language Models," *arXiv preprint arXiv:1908.10063*, 2019.

[4] M. Wooldridge, *An Introduction to MultiAgent Systems*, 2.ª ed. Wiley, 2009.

[5] B. Hu, Y. Hua, L. D. Xu, L. Zheng y Z. Zhou, "Automated trading systems statistical and machine learning methods and hardware implementation: a survey," *Enterprise Information Systems*, vol. 13, n.º 2, págs. 132-144, 2019.

[6] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, n.º 1, págs. 5-32, 2001.

[7] C. Krauss, X. A. Do y N. Huck, "Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the S&P 500," *European Journal of Operational Research*, vol. 259, n.º 2, págs. 689-702, 2017. DOI: 10.1016/j.ejor.2016.10.031

[8] Y. Wang y G. Yan, "Survey on the application of deep learning in algorithmic trading," *Data Science in Finance and Economics*, vol. 1, n.º 4, págs. 345-361, 2021.

[9] Y. Li, S. Wang, H. Ding y H. Chen, "Large Language Models in Finance: A Survey," en *4th ACM International Conference on AI in Finance (ICAIF '23)*, 2023. DOI: 10.1145/3604237.3626869

[10] J. Devlin, M.-W. Chang, K. Lee y K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," *arXiv preprint arXiv:1810.04805*, 2018.

[11] K. Kirtac y G. Germano, "Sentiment trading with large language models," *arXiv preprint arXiv:2412.19245*, 2024.

[12] T. Nie et al., "Large Language Model Agent in Financial Trading: A Survey," *arXiv preprint arXiv:2408.06361*, 2024.

[13] Y. Xiao et al., "TradingAgents: A Multi-Agent LLM Financial Trading Framework," en *arXiv preprint arXiv:2412.20138*, 2024.

[14] X. Yu et al., "FinCon: A Synthesized LLM Multi-Agent System with Concept-Oriented Verbal Reinforcement for Enhanced Financial Decision Making," *arXiv preprint arXiv:2407.06567*, 2024.

[15] T. Loughran y B. McDonald, "When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks," *Journal of Finance*, vol. 66, n.º 1, págs. 35-65, 2011.

[16] C. Zihan, *FNSPID: Financial News and Stock Price Integration Dataset*, HuggingFace Datasets, 2024. dirección: https://huggingface.co/datasets/Zihan1004/FNSPID

[17] A. Q. Jiang et al., "Mistral 7B," *arXiv preprint arXiv:2310.06825*, 2023.

[18] J. W. Wilder, *New Concepts in Technical Trading Systems*. Trend Research, 1978.

[19] J. Bollinger, *Bollinger on Bollinger Bands*. McGraw-Hill, 2001.

[20] W. F. Sharpe, "Mutual Fund Performance," *Journal of Business*, vol. 39, n.º 1, págs. 119-138, 1966.

Apéndice A

Estructura del proyecto

A continuación se describe brevemente el contenido y propósito de cada fichero del proyecto.

Módulos de código (`src/`):

- `sistema_llm_puro.py`: implementa el sistema LLM puro. Contiene los cinco agentes especializados (técnico, fundamental, riesgo, sentimiento y Monte Carlo), el orquestador y la función de generación de señales mensuales para backtesting.
- `sistema_hibrido.py`: implementa el sistema híbrido. Contiene las clases `AgenteRF`, `AgenteSentimientoFinBERT` y `AgentesV3`, junto con la función de simulación Monte Carlo y el orquestador basado en Mistral.

Cuadernos de trabajo (`notebooks/`):

- `01_datos_y_exploracion.ipynb`: descarga los datos de precio histórico vía `yfinance`, descarga el dataset FNSPID desde HuggingFace, y genera el análisis exploratorio del capítulo 4.
- `02_indicadores_tecnicos.ipynb`: calcula y visualiza los indicadores técnicos (RSI, MACD, Bollinger) sobre AAPL, generando las figuras del capítulo 3.
- `03_agentes_llm_e_hibrido.ipynb`: cuaderno de pruebas interactivas para ambos sistemas en modo tiempo real. Permite analizar acciones individuales y entrenar los Random Forest del sistema híbrido.
- `04_backtesting.ipynb`: ejecuta el backtesting histórico completo de las cuatro estrategias (cuantitativa, RF monolítico, LLM puro e híbrido), calcula las métricas y genera las figuras comparativas del capítulo 7.

Datos (`datos/`): contiene los precios históricos en formato parquet por ticker, los datos de entrenamiento 2010–2018 para los Random Forest, y el dataset FNSPID de noticias financieras.

Resultados (`results/`): contiene los modelos entrenados (`.pkl`), las señales mensuales generadas por cada sistema y perfil (`.csv`), y las figuras generadas durante el análisis (`.png`).

```
tfg_multiagente/
|-- notebooks/
|   |-- 01_datos_y_exploracion.ipynb
|   |-- 02_indicadores_tecnicos.ipynb
|   |-- 03_agentes_llm_e_hibrido.ipynb
|   `-- 04_backtesting.ipynb
|-- src/
|   |-- sistema_llm_puro.py
|   `-- sistema_hibrido.py
|-- datos/
|   |-- {TICKER}.parquet
|   |-- {TICKER}_train.parquet
|   `-- fnspid_50tickers.parquet
`-- results/
    |-- modelo_rf_final.pkl
    |-- modelos_v3/
    |-- senales_mensuales_{perfil}.csv
    |-- v3_senales_mensuales_{perfil}.csv
    `-- *.png
```

Apéndice B

Tickers seleccionados del S&P 500

Ticker	Empresa	Sector	Ticker	Empresa
AAPL	Apple	Tecnología	MSFT	Microsoft
NVDA	NVIDIA	Tecnología	GOOGL	Alphabet
META	Meta	Tecnología	AVGO	Broadcom
AMD	AMD	Tecnología	ORCL	Oracle
INTC	Intel	Tecnología	QCOM	Qualcomm
JNJ	Johnson & Johnson	Salud	UNH	UnitedHealth
LLY	Eli Lilly	Salud	ABBV	AbbVie
MRK	Merck	Salud	TMO	Thermo Fisher
ABT	Abbott	Salud	PFE	Pfizer
MDT	Medtronic	Salud	BMY	Bristol-Myers
JPM	JPMorgan	Financiero	BAC	Bank of America
WFC	Wells Fargo	Financiero	GS	Goldman Sachs
MS	Morgan Stanley	Financiero	BLK	BlackRock
AXP	American Express	Financiero	C	Citigroup
USB	U.S. Bancorp	Financiero	PNC	PNC Financial
AMZN	Amazon	Consumo	TSLA	Tesla
HD	Home Depot	Consumo	MCD	McDonald's
NKE	Nike	Consumo	SBUX	Starbucks
TGT	Target	Consumo	LOW	Lowe's
F	Ford	Consumo	GM	General Motors
XOM	ExxonMobil	Energía	CVX	Chevron
COP	ConocoPhillips	Energía	SLB	Schlumberger
EOG	EOG Resources	Energía		—
CAT	Caterpillar	Industrial	BA	Boeing
HON	Honeywell	Industrial	GE	General Electric
LMT	Lockheed Martin	Industrial	—	—